

Bachelorarbeit

Ansatz zur Optimierung einer CI-Pipeline mit reproduzierbaren lokalen Builds

Ruben Leander Rosenmeyer

Gutachter: Prof. Dr. Peter Thiemann

Betreuer: Dr. Michael Sperber

Albert-Ludwigs-Universität Freiburg

Technische Fakultät

Institut für Informatik

13. Juli 2026

Bearbeitungszeit

13. 04. 2026 – 13. 07. 2026

Gutachter

Prof. Dr. Peter Thiemann

Betreuer

Dr. Michael Sperber

ERKLÄRUNG

Hiermit erkläre ich, dass ich diese Abschlussarbeit selbständig verfasst habe, keine anderen als die angegebenen Quellen/Hilfsmittel verwendet habe und alle Stellen, die wörtlich oder sinngemäß aus veröffentlichten Schriften entnommen wurden, als solche kenntlich gemacht habe.

Darüber hinaus erkläre ich, dass diese Abschlussarbeit nicht, auch nicht auszugsweise, bereits für eine andere Prüfung angefertigt wurde.

Ort, Datum

Unterschrift

Hilfsmittel

Bei der Erstellung dieser Bachelorarbeit und der begleitenden Inhalte wurden folgende Tools als Hilfsmittel eingesetzt:

- Chat GPT von Open AI, Modell GPT-5.5
zur Fehlerbehebung und allgemeiner Unterstützung des Schreib- und Codeerstellungsprozesses
- Consensus und Google Scholar
zur Unterstützung der Literaturrecherche
- github Copilot
zur Unterstützung des Schreibprozesses bei der Codegenerierung

Keine KI wurde als eigenständige Quelle verwendet, sondern ausschließlich als unterstützendes Hilfsmittel des Arbeitsprozesses.

Zusammenfassung

Diese Bachelorarbeit beschäftigt sich mit der Entwicklung eines Testframework-agnostischen Verfahrens, welches durch die Entscheidung, welche Testcases für den aktuellen Commit eines Softwareprojektes bereits ausgeführt wurden, und welche nicht, die Laufzeit einer CI-Pipeline bei der Durchführung von Tests reduzieren kann, indem nur Testcases ausgeführt werden, deren Ergebnis noch nicht bekannt ist.

Dazu werden im Rahmen dieser Bachelorarbeit die nötigen Voraussetzungen beleuchtet, um einen möglichst hohen Grad der Framework-Unabhängigkeit zu erreichen. Ebenso wird eine Implementierung des Verfahrens beschrieben, welches das für diesen Zweck erstellte Tool *testAuditor* nutzt. Außerdem werden die Anforderungen an ein Softwareprojekt definiert, die notwendig sind, um das Verfahren in besagtes Projekt integrieren zu können.

Zu Schluss folgt eine Evaluierung, in wie weit die Zielsetzung dieser Bachelorarbeit erfüllt werden konnte.

Begleitet wird diese Arbeit von dem Quellcode von *testAuditor*, einer Demo des Verfahrens in einer exemplarischen Umgebung, sowie einem Datensatz, in dem die Ausgabeformate einer Auswahl von Testframeworks untersucht werden.

Die entsprechenden Repositorien sind in Kapitel 7 verlinkt.

Inhaltsverzeichnis

Zusammenfassung	iii
1 Einleitung	1
1.1 Problemstellung	1
1.2 Zielsetzung	2
2 Hintergrund	4
2.1 Anforderungen an das Verfahren	4
2.2 Anforderungen an ein Testausgabeformat	4
2.3 Generierung eines Testausgabeformats	6
3 Vergleich von Testausgabeformaten	10
3.1 Methodik	10
3.1.1 Struktur der Testdateien	11
3.2 Evaluation der häufigsten Formate	12
3.2.1 JUnit XML	12
3.2.2 Test Anything Protocol (TAP)	18
3.2.3 Open Test Reporting (OTR)	20
3.2.4 Common Test Report Format (CTRF)	21
3.2.5 Andere Formate	22
3.3 Fazit zur Evaluation der Testausgabenformate	22
4 Umsetzung	23
4.1 Anforderungen an ein Projekt	23
4.1.1 Deterministische builds - 'it works on my machine' . .	23
4.1.2 Benötigte Schnittstellen	23
4.2 Anforderungen an ein Framework	24
4.3 Einschränkungen	24
4.4 Codestruktur	25

4.4.1	Parser für JUnit XML	25
4.5	Exemplarischer Ablauf	25
4.6	git notes	25
5	Related Work	26
5.1	Andere Tools	26
6	Fazit	27
6.1	Zusammenfassung der Ergebnisse	27
6.2	Möglichkeiten zur Verbesserung	27
	Bibliography	27
7	Links	29

1 Einleitung

1.1 Problemstellung

”One cannot “test quality into” a badly constructed software product, but neither can one build quality into a product without test and analysis.”

[Pezzè and Young, 2008, S. XVII]

Jedes größere Softwareprojekt benötigt eine Vielzahl von Testfälle (fortfolgend als Testcases bezeichnet), um die Qualität der Software zu sichern. Dabei werden die einzelnen Testcases für gewöhnlich in verschiedene Klassen unterteilt (fortfolgend als Testsuites bezeichnet), die verschiedene Abschnitte der Software abdecken. Die meisten gängigen Testframeworks bieten die Möglichkeit, einzelne Testsuites und/oder Testcases gezielt auszuführen, ohne die restlichen Testcases dabei mit auszuführen.

Nehmen wir z.B. einen Entwickler, der bei einem großen Softwareprojekt die Funktionalität einer Datenbank-Schnittstelle anpasst. Testcases, welche die Funktion dieser Schnittstelle abtesten, sind hier sehr relevant - andere Testcases, die sich mit anderen Abschnitten des Projektes befassen, wie etwa UI-Tests oder Tests für Netzwerkverbindungen, sollten bei einem sauber modularisiertem Projekt mit hoher Wahrscheinlichkeit unabhängig von Änderungen der Datenbank-Schnittstelle das selbe Ergebnis wie vor den Änderungen des Entwicklers liefern. Da manche Testcases viel Zeit für ihre Durchführung in Anspruch nehmen, ist es daher sinnvoll, bei der Entwicklung nur einzelene relevante Abschnitte zu testen.

Dennoch muss zur Validierung des Codes regelmäßig jede Testsuite des Softwareprojektes durchlaufen werden, damit durch das partielle Testen des Codes keine Fehler unbemerkt im Projekt verbleiben.

Um dies zu gewährleisten, wird für gewöhnlich auf dem Build-Server nach einem Commit noch einmal die gesamte Testsuite des Projektes durchlaufen,

auch wenn manche Testcases möglicherweise bereits ausgeführt wurden, ohne dass sich der Code in der Zwischenzeit geändert hat. Dadurch wird die Laufzeit der gesamten CI-Pipeline unnötig verlängert.

1.2 Zielsetzung

Ziel dieser Bachelorarbeit ist das Ermitteln eines Lösungsansatzes für die folgende Fragestellung:

Wie kann die Laufzeit von Testphasen in CI-Pipelines unabhängig von verwendeten Testframework durch die Wiederverwendung bereits vorhandener Testergebnisse reduziert werden, ohne die Aussagekraft des Testergebnisses zu beeinträchtigen?

Zur Beantwortung dieser Frage soll ein Verfahren entwickelt werden, welches anhand der Ergebnisse vergangener Testläufe entscheiden kann, für welche Testcases noch kein Ergebnis vorliegt, und ausschließlich für diese Testcases ein Ergebnis produziert. Dabei muss zwingend eine komplette Abdeckung aller Testcases erhalten bleiben. Das Ergebnis jedes Testcases muss identisch mit dem Ergebnis bei einem kompletten Neudurchlauf aller Testcases sein, mit Ausnahme von Meta-Daten wie beispielsweise dem Zeitstempel des Testdurchlaufs. Dabei soll die Wahl des Testframeworks möglichst keine Rolle spielen.

Gemessen wird der Erfolg der Entwicklung des Verfahrens anhand einer Evaluation, welche für eine beispielhafte Implementierung des Verfahrens folgende Kennzahlen sammelt:

- Gesamtzahl aller Testcases
- Zahl der vom Verfahren als bereits durchgeführt eingestuft Testcases
- Zahl der vom Verfahren als nicht bereits durchgeführt eingestuft

Testcases / durch das Verfahren ausgeführte Testcases

- Laufzeit der Testpipeline unter Verwendung des Verfahrens
- Laufzeit der Testpipeline ohne Verwendung des Verfahrens

Zusätzlich werden die Testergebnisse der Durchläufe mit und ohne Verwendung des Verfahrens miteinander verglichen, um die Gleichwertigkeit der Testergebnisse zu überprüfen.

Nicht Teil dieser Bachelorarbeit sind die folgenden Punkte:

- Authentizität:

Sämtliche Dateien, welche dem Verfahren von einem Projekt zu Verfügung gestellt werden, werden als legitim betrachtet. Eine Überprüfung der Authentizität oder Autorenschaft einzelner Dateien findet nicht statt.

2 Hintergrund

2.1 Anforderungen an das Verfahren

Folgende Anforderungen werden an einen Durchlauf einer CI-Pipeline gestellt, welche das vorgestellte Verfahren nutzt:

- **Die Wahl der verwendeten Programmiersprache(n) und Testframework(s) ist unerheblich**

Das Tool soll framework-agnostisch funktionieren, auch wenn innerhalb des Projektes verschiedene Testframeworks zum Einsatz kommen.

- **Nach Ablauf des Tools wurde jeder Testcase für den aktuellen Stand des Codes mindestens einmal durchgeführt**

Testcases können manuell mehrfach ausgeführt werden, allerdings darf das Tool selbst keinen Testcase ausführen, der bereits ausgeführt wurde, um die Laufzeit der Testphase so gering wie möglich zu halten. Trotzdem muss die gesamte Testsuite komplett abgedeckt sein, um die Aussagekraft des Testlaufes im Vergleich zu einem komplett neuen Durchlauf nicht zu beeinträchtigen.

2.2 Anforderungen an ein Testausgabeformat

Jedes Testframework verfügt über eines oder mehrere mögliche Ausgabeformate, welches die Informationen über das Ergebnis eines Testlaufes enthält. Damit ein Tool entwickelt werden kann, welches möglichst frameworkunabhängig funktioniert, muss ein Ausgabeformat gefunden werden, dass von möglichst vielen verschiedenen Testframeworks auf die selbe Art und Weise verwendet wird, damit die Dateien vom Tool über eine Schnittstelle eingelesen werden können.

Mit Blick auf diese sowie die unter Kapitel 2.1 beschriebenen Anforderungen

an das Tool, ergeben sich folgende Anforderungen an ein potentielle nutzbare Ausgabeformat:

Ein ideales Ausgabeformat für Tests:

- **enthält die Gesamtmenge aller Tests im Projekt**

Dieser Punkt ist essenziell, zum einen um eine Aussage darüber treffen zu können, ob eine 100%ige Testcoverage erzielt wurde, zum anderen muss das Tool zum Erzielen einer absoluten Coverage auch auf potentiell jeden vorhandenen Testcase zugreifen können. Dazu muss dem Tool selbstverständlich auch jeder Testcase innerhalb des Projektes bekannt sein.

- **identifiziert jeden Testcase eindeutig**

Je nach Testframework und Implementierung ist es gestattet, mehreren Testcases, die in unterschiedlichen Namespaces leben, mit dem selben Namen zu bezeichnen. Aus dem Ausgabeformat muss in jedem Falle eine eindeutige Zuordnung der Testcases und den Ergebnissen möglich sein.

- **sagt für jeden Testcase einzeln aus, ob er ausgeführt wurde oder nicht**

- **ist ein strukturiertes Format**

Es muss eine erfassbare Struktur für das Testausgabeformats vorhanden sein, damit ein entsprechender Parser für das Tool entwickelt werden kann.

- **ist in vielen Frameworks über viele Programmiersprachen hinweg vertreten**

Es wäre utopisch anzunehmen, dass ein strukturiertes Format existiert, welches von jedem existierendem Testframework gleichermaßen

benutzt wird. Dennoch gibt es durchaus gängige Formate, die von unterschiedlichen Testframeworks aus unterschiedlichen Sprachen unterstützt werden, wie folgend in Kapitel 3 untersucht wird.

2.3 Generierung eines Testausgabeformats

Die genaue Struktur und das finale Aussehen der Ausgabe eines Testlaufes hängen im Wesentlichen von den folgenden Faktoren ab, deren Aufteilung der in Winkler et al. [2009] vorgestellten Struktur eines Testframeworks folgt:

- **Struktur der zugrunde liegenden Testdateien:**

Die (Nicht-)Verwendung von Klassen, Testsuites oder anderen vom Testframework oder der Programmiersprache bereitgestellten Optionen zur Organisation der Testcases, sowie die Dateistruktur der Testdateien können einen Einfluss auf das Endresultat haben

- **verwendetes Testframework**

- **verwendetes Testausgabeformat:**

Damit ist sowohl das Dateiformat, als auch die Wahl eines strukturierten Ausgabeformats gemeint. Näheres dazu in Kapitel 3.

- **Test Runner:**

Auch als *Scheduler*, *Harness* oder *Orchestrator* bezeichnet, beschreibt der Begriff "Test Runner" hier die Komponente eines Testframeworks, welche die Testcases ausführt, und die Ergebnisse an den Test Reporter weiterreicht. Der Test Runner beeinflusst beispielsweise die Darstellung von Ereignissen, die während der Ausführung der Testsuite auftreten und in die Ausgabe übernommen werden.

- **Test Reporter:**

Auch als *test generator* bezeichnet, beschreibt "Test Reporter" hier jene Komponente eines Testframeworks, welche aus dem vom Test Runner bestimmten Ergebnis der Testsuite die menschen- bzw. maschinenlesbare Ausgabe generiert.

In den meisten Testframeworks übernimmt das Testframework selbst die Aufgaben des Test Runners und des Test Reporters, in manchen Fällen werden diese Komponenten aber auch durch andere Prozessen bereitgestellt. Dies ist zum Beispiel in der Programmiersprache Java der Fall: Hier stellen die beiden build-tools maven und gradle jeweils ihre eigenen Test Runner bzw. Test Reporter zur Verfügung, was unterschiedliche Kombinationen aus Testframework, Test Runner und Test Reporter erlaubt. Dass dies auch zu Unterschieden in der Testausgabe führen kann, ist in Codeblock 2.1 dargestellt.

JUnit5, Jupiter:

```
<?xml version="1.0" encoding="UTF-8"?>
<testsuite name="JUnit Jupiter" tests="5" skipped="1" failures="1"
  errors="0" time="0.036" hostname="DESKTOP-I9APAL0"
  timestamp="2026-07-04T00:45:01">
  <properties>
  <property name="file.encoding" value="UTF-8"/>
  <property name="file.separator" value="/" />
  ...
  <testcase name="test_neg()" classname="BasicTest" time="0.006">
```

JUnit5, Jupiter mit maven surefire:

```
<?xml version="1.0" encoding="UTF-8"?>
<testsuite xmlns:xsi="http://www.w3.org/2001/XMLSchema-instance"
  xsi:noNamespaceSchemaLocation=
  "https://maven.apache.org/surefire/maven-surefire-plugin/xsd/surefire-test-report.xsd"
  version="3.0.2" name="BasicTest" time="0.013" tests="4" errors="0"
  skipped="1" failures="1">
  <properties>
  <property name="java.specification.version" value="21"/>
```

```

    <property name="sun.jnu.encoding" value="UTF-8"/>
    ...
    <testcase name="test_neg" classname="BasicTest" time="0.0"/>
    ...
Junit5, Jupiter mit gradle test task:
    <?xml version="1.0" encoding="UTF-8"?>
    <testsuite name="BasicTest" tests="4" skipped="1" failures="1" errors="0"
        timestamp="2026-07-03T22:47:00.701Z"
        hostname="DESKTOP-I9APAL0" time="0.009">
    <properties/>
    <testcase name="test_neg()" classname="BasicTest" time="0.001"/>
    ...

```

Codeblock 2.1: direkter Vergleich von Junit XML, erzeugt durch Junit5 mit Jupiter in Java. Jeder Ausgabe liegen die selben beiden Testdateien zu Grunde.
... bezeichnet gekürzte Stellen.

Obwohl für jede Ausgabe Junit5 mit Jupiter als Testframework benutzt wird, jede Ausgabe Junit XML als Format aufweist, und jede Ausgabe auf den selben beiden Testdateien basiert, gibt es durch die unterschiedlichen Test Runner und Test Reporter deutliche Unterschiede in der Testausgabe.

So ignoriert gradle beispielsweise in diesem exemplarischen Fall das tag `<properties>`, während maven und Jupiter (ohne build-tool) eine exessive Liste von `<property>` in der Testausgabe mitgeben.

Auch die Benennung der Testcases unterscheidet sich:

Jupiter und gradle behalten den Namen `test_neg()` bei, so wie er auch in der Testdatei verwendet wird, während maven den Namen zu `test_neg` kürzt.

Ähnliches bei der Benennung der Testsuite: Da gradle und maven für jede Datei eine eigene Ausgabedatei erzeugen, benutzen die beiden build-tool den Namen der jeweiligen Testsuite, hier "BasicTest", als Wert des Attributes "name" im tag `<testsuite>`. Jupiter gibt dagegen nur eine Ausgabedatei aus, die das

Ergebnis aller Testdateien enthält, und benutzt in dieser den Standardwert "JUnit Jupiter" als Namen für <testsuite>.

3 Vergleich von Testausgabeformaten

Um ein Tool zu entwickeln, welches framework-agnostisch eingesetzt werden kann, muss dieses Tool die Ausgabe eines Testlaufes unabhängig vom verwendeten Framework parsen können. Die Anforderungen an ein Testausgabeformat wurden bereits in Kapitel 2.2 untersucht.

Standartmäßig geben die meisten Testframeworks das Ergebnis eines Testlauf in einem unstrukturiertem Format über die Konsole aus. Allerdings bieten fast alle etablierten Testframeworks auch eine Auswahl an Dateiformaten an, über welche die Testausgabe ebenfalls präsentiert werden kann.

Für diese Dateiformate wurden über die Jahre einige framework-übergreifende Ausgabeformate entwickelt, die sich in unterschiedlicher Ausprägung durchsetzen konnten.

Es gilt nun, ein geeignetes Testausgabeformat zu finden, dass vom Tool als Eingabe benutzt werden kann.

3.1 Methodik

Aufgrund der Vielzahl von verschiedenen Testframeworks und der Vielfältigkeit ihrer Ausgabeformate können im Rahmen dieser Bachelorarbeit nur die verbreitesten Formate untersucht werden.

Zur Untersuchung der praktischen Umsetzung einzelner Formate und zur exemplarischer Erfassung ihrer Verbreitung wird ein limitierter Datensatz betrachtet. Dabei gilt zu beachten, dass bei diesem Datensatz nur eine kleine Menge von Programmiersprachen beinhaltet. Außerdem beschränken sich die untersuchten Testframeworks auf die am weitesten verbreiteten in ihrer jeweiligen Sprache, um die Etablierung von Testausgabeformaten möglichst praxisnahe darstellen zu können. Außerdem bieten länger etablierte Testfra-

meworks erfahrungsgemäß eine breitere Auswahl von Testausgabeformaten, als weniger verbreitete Testframeworks.

Bei der Untersuchung von Plugins für zusätzliche Testausgabeformate wurden ausschließlich Plugins berücksichtigt, welche über den hier benutzten package manager nix bereitgestellt werden. Würden externe Plugins, zumeist über unabhängig gepflegte Repositorien, ebenfalls betrachtet werden, würde die Zahl der unterstützten Testausgabeformate bei den meisten untersuchten Testframeworks deutlich steigen. Da keine Aussage über die Vertrauenswürdigkeit und Qualität der externen Plugins getroffen werden kann, beschränkt sich diese Untersuchung auf von nix bereitgestellte Plugins.

3.1.1 Struktur der Testdateien

Die Struktur der Testdateien wird für jede untersuchte Programmiersprache möglichst identisch gehalten:

Es existieren zwei Testdateien. Sofern das Testframework die Möglichkeit bereitstellt, besitzt jede der Dateien ihren eigenen Namespace. Die Bezeichnung der Namespace kann variieren, da manche Testframeworks eine bestimmte Namenskonvention voraussetzen.

In der ersten Datei liegen 4 Testcases im Namespace **BasicTest**:

- **test_neg**: Ein einfacher Testcase, der eine korrekte Assertion beinhaltet und nicht fehlschlägt.
- **test_pos**: Ein einfacher Testcase, der eine falsche Assertion beinhaltet und fehlschlägt.
- **test_skip**: Ein Testcase, der übersprungen wird. Manche Testframeworks unterscheiden zwischen übersprungenen, und ignorierten Testcases: Übersprungene Testcases werden nicht ausgeführt, aber als übersprungen in der Testausgabe markiert. Ignorierte Testcases werden

werder ausgeführt, noch in die Testausgabe übernommen. Letzteres ist für die Evaluation der Testausgabeformate uninteressant.

- **test_same_name:** Ein einfacher Testcase, der eine korrekte Assertion beinhaltet und nicht fehlschlägt. In der zweiten Datei existiert ein Testcase mit dem selben Namen.

In der zweiten Datei liegt ein Testcase im Namespace **BasicTest2**:

- **test_same_name:** Ein einfacher Testcase, der eine korrekte Assertion beinhaltet und nicht fehlschlägt. In der ersten Datei existiert ein Testcase mit dem selben Namen.

test_same_name untersucht, ob es aus der Testausgabe heraus möglich ist, einen Testcase eindeutig zu indentifizieren, auch wenn in unterschiedlichen Namespaces verschiedene Testcases den selben Namen aufweisen.

Tabelle 1 zeigt die Ergebnisse des Datensatzes zur Untersuchung der Verbreitung von Testausgabeformaten.

3.2 Evaluation der häufigsten Formate

In diesem Kapitel werden die häufigsten frameworkübergreifend verwendeten Testausgabeformate kurz vorgestellt und nach den in Kapitel 2.2 festgesetzten Kriterien auf ihre Eignung zur Benutzung als Testausgabeformat für das zu entwickelnde Tool evaluiert.

3.2.1 JUnit XML

Übersicht

JUnit XML ist ein XML-basiertes Format, welches ursprünglich für das Java-Testframework JUnit entwickelt wurde. Für JUnit XML existiert kein einheitlicher Standart, d.h. es existiert auch keine beschreibendes .xsd Sche-

Framework	Sprache	JUnit XML	XML (anderes)	OTR	TAP	JSON	HTML
catch2	C++	✓	✓	✗	✓	✗	✗
doctest	C++	✓	✓	✗	✗	✗	✗
gtest	C++	✓	✗	✗	✗	✓	✗
hspec	Haskell	~	✗	✗	✗	✗	✗
tasty	Haskell	~	✗	✗	~	✗	✗
junit5/jupiter	Java	✓	✗	✓	✗	✗	✗
junit5/jupiter (maven surefire)	Java	✓	✗	~	✗	✗	~
junit5/jupiter (gradle test task)	Java	✓	✗	~	✗	✗	✓
behat	PHP	✓	✗	✗	✗	✓	✗
codeception	PHP	✓	✗	✗	✗	✗	✓
phpunit	PHP	✓	✗	✓	✗	✗	✓
pytest	Python	✓	✗	✗	~	~	~
unittest	Python	✓	✗	✗	✗	✗	✗

✓ Nativ unterstützt
 ~ Über Plugins unterstützt
 ✗ Nicht offiziell unterstützt

Tabelle 1: Übersicht der Verbreitung bestimmter Formate

ma, wie sonst für XML Formate üblich. Trotzdem wurde JUnit XML von vielen Testframeworks in gleicher oder ähnlicher Form adaptiert, wie es ursprünglich für JUnit entworfen wurde. Außerdem existieren viele weitere für das Software-Testing relevante Programme, welche JUnit XML verarbeiten können, beispielsweise viele CI/CD-Systeme. Auf diese Weise hat sich JUnit XML zu einem De-Facto Standard für Ausgabeformate von Testframeworks entwickelt.

Struktur

Wie bereits erwähnt gibt es bei JUnit XML keine standardisiertes Schema. Allerdings haben sich einige Strukturen durchgesetzt, die von nahezu allen Testframeworks, welche JUnit XML als Testausgabeformat anbieten, verwendet werden. Ein typisches Beispiel für die häufigste Struktur ist Codeblock 3.1:

```
<?xml version="1.0" encoding="UTF-8"?>
<testsuites name="default">
  <testsuite name="Basic tests" file="features/basic.feature" tests="4"
    skipped="0" failures="2" errors="0" time="0.006">
    <testcase name="test_neg" classname="Basic tests" status="passed"
      time="0.004" file="features/basic.feature" line="4"></testcase>
    ...
  
```

Codeblock 3.1: JUnit XML, erzeugt durch das PHP-Testframework behat. ... bezeichnet gekürzte Stellen.

Das root-element `<testsuites>` enthält eine Menge von `<testsuite>`-tags, welche jeweils eine Menge von `<testcase>`-tags enthalten. Jedes `<testcase>`-tag steht für einen Testcase aus der ursprünglichen Testsuite des zu testenden Programms und enthält für gewöhnlich Informationen über das Testergebnis, den Ablauf, und den ursprünglichen Testcase. Hier ist allerdings wieder wichtig zu erwähnen, dass der Inhalt dieses tags ebenso wenig standardisiert ist, wie der Inhalt der übrigen tags. Deutlich wird dieser Sachverhalt in

Codeblock 3.2. Unterschiede in der grundlegenden Struktur zeigen sich z.B. in Codeblock 3.3. Hier wird das tag `<testsuite>` verschachtelt verwendet, statt wie sonst üblich nur einmal.

```

junit5 (maven), Java:
<testcase name="test_neg" classname="BasicTest" time="0.012"/>

phpunit, PHP:
<testcase name="test_neg" file="/home/.../test.php" line="7"
    class="BasicTest" classname="BasicTest" assertions="1"
    time="0.000645"/>

gtest, C++:
<testcase name="test_neg" file="./test/gtest/test.cpp" line="3"
    status="run" result="completed" time="0."
    timestamp="2026-06-29T22:44:17.561" classname="BasicTests" />

```

Codeblock 3.2: direkter Vergleich verschiedener Implementierungen des `<testcase>`-tags in ausgewählten JUnit-XML Ausgaben. Verglichen wird jeweils die Ausgabe des fehlerlosen, nicht übersprungenen Testcases `test_neg`. ... bezeichnet gekürzte Stellen.

```

<?xml version='1.0'?>
<testsuites errors="0" failures="1" tests="5" time="0.001">
  <testsuite name="AllTests" tests="5">
    <testsuite name="Test1" tests="4">
      <testcase name="test_neg" time="0.000"
        classname="AllTests.Test1" />
    ...
  ...
</testsuites>

```

Codeblock 3.3: JUnit XML, erzeugt durch das Haskell-Testframework `tasty` mit dem `ant`-Plugin. ... bezeichnet gekürzte Stellen.

Aus Codeblock 3.2 ist ersichtlich, dass sich die benutzten Attribute des `<testcase>`-tags sowie deren Inhalt stark unterscheiden können, jedoch werden zwei Attribute für gewöhnlich gesetzt und in gleicher Weise verwendet:

- name= enthält den namen des Testcase
- classname= enthält den namespace bzw. die Klasse des Testcase

Dieser Trend aus Codeblock 3.2 setzt sich auch in den übrigen im Datensatz untersuchten JUnit XML Ausgaben fort. Es gibt zwar einige wenige Ausnahmen wie exemplarisch in Codeblock 3.4 dargestellt, diese sind jedoch eher selten. Eine ausführliche Übersicht, wie häufig diese eindeutige Zuordnung zwischen Testergebnis und Testcase möglich ist, ist in Tabelle 2 zu finden.

```
<testcase name="test_neg" class="BasicTest" file="/home/.../Test.php"
time="0.000252" assertions="1"/>
```

Codeblock 3.4: JUnit XML für den Testcase test_neg, erzeugt durch das PHP-Testframework codeception. Codeception benutzt statt dem häufig verwendeten Attribut "classname" das Attribut "class".
... bezeichnet gekürzte Stellen.

Eignung

Da JUnit XML ursprünglich spezifisch für das Testframework Junit entwickelt wurde, folgt die grundlegende Struktur den Gegebenheiten und Anforderungen dieses Frameworks. Zwar folgen viele weitere Testframeworks auch in anderen Sprachen einer ähnlichen Struktur oder können die Junit XML Struktur trotz einiger Unterschiede benutzen, in einzelnen Fällen kommt es jedoch zu Schwierigkeiten und ungewöhnlichen Anpassungen der XML-Struktur.

Abgesehen davon ist Junit XML das einzige Testausgabeformat, dass von jedem im Datensatz untersuchten Testframework ausgegeben werden kann, zumeist sogar nativ, vereinzelt muss die Unterstützung erst über offiziell unterstützte Plugins hinzugefügt werden. Für viele Testframeworks ist Junit XML das primäre strukturierte Ausgabeformat für ihre Testläufe.

Framework	Sprache	Zuordnung über name+classname	Zuordnung über alternativen Attribute	Namen der alternativen Attribute
catch2	C++	✓	~	~
doctest	C++	✓	~	~
gtest	C++	✓	~	~
hspec	Haskell	✓	~	~
tasty	Haskell	✓	~	~
junit5	Java	✓	~	~
junit5	Java (maven)	✓	~	~
junit5	Java (gradle)	✓	~	~
behat	PHP	✓	~	~
codeception	PHP	✗	✓	name+class
phpunit	PHP	✓	~	~
pytest	Python	✓	~	~
unittest	Python	✓	~	~



Eindeutige Zuordnung möglich



nicht notwendig



Eindeutige Zuordnung nicht möglich

Tabelle 2: Übersicht zur eindeutigen Zuordnung vom Testergebnis zum ursprünglichen Testcase über Attribute in Junit XML

Fazit zu JUnit XML

Aufgrund der weiten Verbreitung und der in der Praxis ähnlichen Umsetzung in vielen Frameworks ist JUnit XML trotz der fehlenden Standardisierung ein geeignetes Testausgabeformat für das Tool, welches mit einer Vielzahl von Testframeworks kompatibel ist.

3.2.2 Test Anything Protocol (TAP)

Übersicht

Das Test Anything Protocol wurde ursprünglich für die Programmiersprache Perl entworfen, wurde über die Jahre hinweg jedoch auch für Testframeworks in anderen Sprachen weiter entwickelt. Anders als bei JUnit XML wird für TAP ein standardisiertes Schema bereitgestellt und gepflegt (<https://testanything.org/tap-version-14-specification.html>). Anders als die meisten anderen hier untersuchten Testausgabeformate ist TAP keine spezialisierte Struktur eines bereits bestehenden Dateiformates, sondern ein eigenständiges Format.

Struktur

Zu Beginn einer Datei wird die Gesamtzahl aller Testcases der Datei angegeben. Danach folgt eine Auflistung der Testergebnisse mit optionalen Zusatzinformationen, zumeist der Name des Testcase. Übersprungene Tests können über zusätzliche Dekoratoren idikatiert werden, die in TAP als "Directives" bezeichnet werden.

Da die meisten Zusatzinformationen optional sind, zeigt Codeblock 3.5 bereits eine vollständig gültige, minimale TAP-Datei:

```
1..1
ok
```

Codeblock 3.5: Minimales TAP-Beispiel

Solch eine Darstellung ist natürlich ungeeignet, da so keine Zuordnung zwischen Testergebnis und Testcase möglich ist. In der Praxis kann dieser Zusammenhang allerdings durch die optionalen Zusatzinformationen gesesetzt werden, wie beispielhaft mit pytest in Codeblock 3.6 demonstriert:

```
# TAP results for test/pytest/test.py
ok 1 test/pytest/test.py::test_neg
not ok 2 test/pytest/test.py::test_pos
...
ok 3 test/pytest/test.py::test_skip # SKIP ...
ok 4 test/pytest/test.py::test_same_name
1..4
```

Codeblock 3.6: TAP, erzeugt durch pytest.
... bezeichnet gekürzte Stellen.

Eignung

Eine eindeutige Zuordnung zwischen Testergebnis und Testcase ist nicht in allen untersuchten Testframeworks, die TAP als Ausgabeformat bieten, möglich. Nehmen wir catch2: Zwei Testscases dürfen in diesem Framework den selben Namen aufweisen, solange sie mit unterschiedlichen Labels getaggt sind. Diese Zusatzinformationen sind allerdings nicht zwingend im TAP-Format erforderlich, und werden vom catch2-Reporter schlicht nicht übernommen. Dies kann eine Ausgabe wie in Codeblock 3.7 zur Folge haben, bei der zwei Testergebnisse mit dem selben Namen bezeichnet werden:

```
...
# test_same_name
not ok 3 — false
# test_same_name
ok 4 — true
...
```

Codeblock 3.7: TAP, erzeugt durch catch2.
... bezeichnet gekürzte Stellen.

Dies macht TAP in diesem Falle als Ausgabeformat ungeeignet. Andere Testframeworks wie beispielsweise pytest oder tasty sorgen allerdings für eine eindeutige Zuordnung in ihren jeweiligen Ausgaben.

Fazit zu TAP

TAP ist aufgrund seiner sehr geringen Minimalstruktur und vor allem seiner nur mäßigen Verbreitung eher nicht als Testausgabeformat für das Tool geeignet.

3.2.3 Open Test Reporting (OTR)

Übersicht

Open Test Reporting (OTR) wird von dem selben Entwicklerteam, welches auch hinter dem Framework JUnit und damit auch hinter JUnit XML steht, als Nachfolger von eben diesem entwickelt. Dabei haben sie laut eigenen Angaben das Ziel, mit OTR die historisch gewachsenen Probleme von JUnit XML (siehe Kapitel 3.2.1) zu umgehen. OTR soll nach Vorstellungen der Entwickler auf lange Sicht JUnit XMLs Platz als de-facto Standard-Ausgabeformat für Testläufe einnehmen.

Anders als die anderen vorstellten Formate gibt es bei OTR zwei mögliche Dateiformate: Es gibt Implementierungen für XML und HTML. Beide Implementierungen sind im Gegensatz zu JUnit XML standardisiert und folgen einem definiertem Schema. Beim XML-Format wird zwischen zwei Strukturen unterschieden: Hierarchisch und eventbasiert. Beide Formate nutzen das selbe Set von Kernelementen, unterscheiden sich aber in ihrer Struktur. Für beide Strukturen gibt es Programmiersprachen-spezifische Erweiterungen.

Das HTML-Format wird ausgehend von einer vorher erzeugten OTR-XML Datei erzeugt, und ist ebenso erweiterbar.

Struktur

Eignung

Da OTR zum Zeitpunkt der Niederschrift dieser Bachelorarbeit noch sehr jung ist und aktiv entwickelt wird, bleibt abzuwarten, ob die Entwickler ihr Ziel eines standardisierten, Programmiersprachen-agnostischen Testausgabeformates erreichen können.

Außerdem ist die Verbreitung von OTR noch sehr limitiert: Von den in Tabelle 1 betrachteten Testframeworks ist lediglich phpunit in der Lage, OTR nativ zu erzeugen. Außerdem kann junit5 (welches, wie eingangs erwähnt, vom selben Entwicklerteam wie OTR betreut wird) zumindest über Plugins eine OTR-Ausgabe erzeugen.

Fazit zu OTR

3.2.4 Common Test Report Format (CTRF)

Übersicht

Ähnlich wie JUnit XML ein spezielles Format für das Dateiformat XML ist, so gibt es auch ein spezielles Testausgabeformat für JSON: Das Common Test Report Format, kurz CTRF. Ähnlich wie OTR ist CTRF zum aktuellen Zeitpunkt ein noch sehr junges Format, welches aktiv weiterentwickelt wird. Dies zeigt sich auch in seiner Verbreitung: Keine der in Tabelle 1 untersuchten Testframeworks bieten die Möglichkeit, CTRF zu erzeugen, weder nativ noch über ein offizielles Plugin.

CTRF ist dennoch interessant zu untersuchen, da es zum Einen das einzige größere frameworkagnostische JSON-Format ist, und zum Anderen, da es

striktere Vorgaben für seine Struktur als die anderen zuvor untersuchten Testausgabeformate macht.

Struktur

Was CTRF aus den übrigen Formaten herausstechen lässt, ist die Tatsache, dass ein Name für Testcases in der Ausgabe zwingend erforderlich ist.

Eignung

Fazit zu CTRF

3.2.5 Andere Formate

teamcity, testdox?

Neben den bisher untersuchten ganz oder teilweise strukturierten Formaten

Selbes Problem wie JSON. Beispielsweise HTML, CSV, Markdown etc. Nicht strukturierte Ausgaben (pretty etc.) werden nicht betrachtet.

3.3 Fazit zur Evaluation der Testausgabeformate

Anhand der Evaluation der unterschiedlichen Testausgabeformate in Kapitel 3 wird deutlich, dass es keinen eindeutigen Kandidaten für die Auswahl des Testausgabeformats, welches alle in Kapitel 2.2 gelisteten Anforderungen erfüllt.

Ein gemeinsames Problem: zeigen keine nicht-ausgeführten tests an

4 Umsetzung

4.1 Anforderungen an ein Projekt

4.1.1 Deterministische builds - 'it works on my machine'

Damit das Tool eine qualifizierte Aussage über die Testergebnisse treffen kann, muss gewährleistet sein, dass alle Tests unabhängig von der Entwicklungsumgebung immer das selbe Testergebnis liefern. Ein Testfall, der auf der Machine eines Entwicklers ein bestimmtes Ergebnis liefert, muss auch zwingend auf einem Build-Server das selbe Ergebnis liefern. Andernfalls könnte eine Diskrepanz zwischen den Testergebnissen zu einer verfälschten Aussage des Tools über den aktuellen Stand der Test führen.

Da Junit XML nicht alle in Kapitel 2.2 aufgeführten Anforderungen erfüllt, ergeben sich einige weitere Anforderungen an ein Projekt, das das Tool nutzen möchte, um trotzdem das geforderte Ziel zu erreichen.

4.1.2 Benötigte Schnittstellen

test discovery

Damit das Tool die Gesamtmenge aller Tests im Projekt kennt, muss im Projekt ein Script vorhanden sein, welches die die Gesamtmenge aller Tests in einem spezifiziertem Format ausgibt.

-> qualifiedname: Eine Zeichenfolge, die einen Test innerhalb eines Testframeworks eindeutig identifiziert. Beispiele in vers. TestFrameworks bringen!

-> Hier Format beschreiben/definieren

test execution

Zum Anderen muss dem Tool ein zweites Script zur Verfügung gestellt werden, welches eine Liste von zuvor in Kapitel 4.1.2 beschriebenen qualifiedNames entgegennimmt, nur diese Tests ausführt, und das Ergebnis (auch wieder JUnit XML) an das Tool zurückmeldet, welches dann diesen Input zusätzlich an die gitnotes anhängt.




Abbildung 1: Schematische Darstellung der Interaktion zwischen CI, lokalem Entwickler, Script und Hilfskomponenten

4.2 Anforderungen an ein Framework

- kann JUnit XML
- enthält essenzielle Informationen für einen Test (genau ausführen!)
- kann tests einzeln aufrufen

4.3 Einschränkungen

- Annahme: keine deliberate bad actors; keine Authentifizierung
- Annahme: An gitnotes angehängte Dateien spiegeln aktuellen Stand vom Code wieder, keine Veränderung der Codebase im Nachhinein

4.4 Codestruktur

4.4.1 Parser für JUnit XML

- Parser des tools - leerzeilen als standart-separator von gitnotes

4.5 Exemplarischer Ablauf

```
git notes add -F "$(realpath code/out/report.xml)"HEAD
```

4.6 git notes

müssen nicht zwingend verwendet werden, auch andere Kommunikationswege mit Tool könnten etabliert werden. Hier nur Mittel der Wahl, weil ändern Code nicht.

Nicht zu empfehlen: Dateien im repo lagern.

5 Related Work

5.1 Andere Tools

Abgrenzung zu z.B Bazel/Gradle?

6 Fazit

6.1 Zusammenfassung der Ergebnisse

<https://xkcd.com/927/>

6.2 Möglichkeiten zur Verbesserung

In seiner aktuellen Form kann das Tool nicht entscheiden, ob die XML-Ausgabe der Tests auch tatsächlich aus dem aktuellen Stand des Codes entstammt, oder ob im Nachhinein Änderungen an dem zu testenden Code oder den Tests selber vorgenommen wurden, was die Aussagekraft des Tools stark beeinträchtigt.

Ein anderes Problem ist, dass das Tool alle Tests, die nicht an den letzten Schwung gitnotes anhängt sind, als nicht abgelaufen betrachtet, auch wenn einige Testfälle in einer vorherigen Iteration ausgeführt sein könnten, und die Änderungen, die seither im Code gemacht wurden diese Tests überhaupt nicht betreffen.

Eine Möglichkeit, dieses Problem zu beheben, wäre die Integration eines neuen Tools, welches eine Seletive Regression Testing / Regression Test Selection implementiert, und so dem Tool rückmelden kann, welche Tests tatsächlich neu ausgeführt werden müssen, und bei welchen der vorherige Stand noch gültig ist.

Zusätzliche Unterstützung von TAP wäre realistisch, JSON formate eher unrealistisch. Robuster machen für name+classname kombis -> Ekstazi
<https://github.com/gliga/ekstazi>

Literaturverzeichnis

Mauro Pezzè and Michal Young. *Software Testing and Analysis: Process, Principles, and Techniques*. 2008.

Dietmar Winkler, Reinhard Hametner, and Stefan Biffl. Automation component aspects for efficient unit testing. In *2009 IEEE Conference on Emerging Technologies & Factory Automation*. IEEE, 2009. doi: 10.1109/ETFA.2009.5347022.

7 Links

Evaluation der Testausgabeformate der Testframeworks:

https://github.com/Zip-creations/evaluate_testformats

Proof-of-concept Umsetzung des in der Bachelorarbeit vorgestellten

Tools:

<https://github.com/Zip-creations/testAuditor>

Exemplarische Einbettung des Tools in ein Python-project mit

pytest:

https://github.com/Zip-creations/BA_showcase