

Bachelorarbeit

Entwicklung eines
framework-agnostischen Verfahrens zur
Optimierung von Testläufen durch
Wiederverwendung von Testergebnissen

Ruben Leander Rosenmeyer

Gutachter: Prof. Dr. Peter Thiemann

Betreuer: Dr. Michael Sperber

Albert-Ludwigs-Universität Freiburg

Technische Fakultät

Institut für Informatik

13. Juli 2026

Bearbeitungszeit

13.04.2026 – 13.07.2026

Gutachter

Prof. Dr. Peter Thiemann

Betreuer

Dr. Michael Sperber

ERKLÄRUNG

Hiermit erkläre ich, dass ich diese Abschlussarbeit selbständig verfasst habe, keine anderen als die angegebenen Quellen/Hilfsmittel verwendet habe und alle Stellen, die wörtlich oder sinngemäß aus veröffentlichten Schriften entnommen wurden, als solche kenntlich gemacht habe.

Darüber hinaus erkläre ich, dass diese Abschlussarbeit nicht, auch nicht auszugsweise, bereits für eine andere Prüfung angefertigt wurde.

Ort, Datum

Unterschrift

Hilfsmittel

Bei der Erstellung dieser Bachelorarbeit und der begleitenden Inhalte wurden folgende Tools als Hilfsmittel eingesetzt:

- **ChatGPT von OpenAI, Modell GPT-5.5**

zur Fehlerbehebung und allgemeinen Unterstützung des Schreib- und Co-deerstellungsprozesses, sowie Erstellung von tikz-Grafiken

- **Consensus und Google Scholar**

zur Unterstützung der Literaturrecherche

- **GitHub Copilot**

zur Unterstützung des Schreibprozesses bei der Codegenerierung

Keine KI wurde als eigenständige Quelle verwendet, sondern ausschließlich als unterstützendes Hilfsmittel des Arbeitsprozesses.

Zusammenfassung

Diese Bachelorarbeit beschäftigt sich mit der Entwicklung eines Testframework-agnostischen Verfahrens, welches die Laufzeit der Durchführung von Tests in einem Softwareprojekt reduzieren kann. Dies soll erreicht werden, indem nur Testcases ausgeführt werden, deren Ergebnis noch nicht bekannt ist.

Dazu werden im Rahmen dieser Bachelorarbeit die nötigen Voraussetzungen beleuchtet, um einen möglichst hohen Grad der Framework-Unabhängigkeit zu erreichen. Ebenso wird eine Implementierung des Verfahrens beschrieben, welches das für diesen Zweck erstellte Tool `testAuditor` nutzt. Außerdem werden die Anforderungen an ein Softwareprojekt definiert, die notwendig sind, um das Verfahren in besagtem Projekt integrieren zu können. Zum Schluss folgt eine Evaluation, in wieweit die Zielsetzung dieser Bachelorarbeit erfüllt werden konnte.

Begleitet wird diese Arbeit von dem Quellcode von `testAuditor`, eines Prototypen des Verfahrens in einer exemplarischen Umgebung, einer Benchmark, in welcher die Laufzeiten des Verfahrens mit den Laufzeiten eines regulären Durchlaufs in verschiedenen Testszenarien gegenübergestellt werden, sowie einem Datensatz, in dem die Ausgabeformate einer Auswahl von Testframeworks untersucht werden.

Die entsprechenden Repositorien sind in Kapitel 8 verlinkt.

Inhaltsverzeichnis

Zusammenfassung	iii
1 Einleitung	1
1.1 Problemstellung	1
1.2 Zielsetzung	2
1.3 Begrenzung des Scope	3
1.4 Aufbau der Arbeit	3
2 Verwandte Themengebiete	5
2.1 Test Impact Analysis (TIA)	5
2.2 Regression Test Selection (RTS)	6
2.3 Build Caching	6
3 Grundlagen und Analyse der Anforderungen	8
3.1 Anforderungen an das Verfahren	8
3.2 Anforderungen an ein Testausgabeformat	9
3.3 Reproduzierbare Builds - 'it works on my machine'	10
3.4 Entstehung eines Testausgabeformats	11
4 Vergleich von Testausgabeformaten	15
4.1 Evaluation des Datensatzes	15
4.1.1 Methodik	15
4.1.2 Struktur der Testdateien	16
4.2 Evaluation der häufigsten Formate	18
4.2.1 JUnit XML	18
4.2.2 Test Anything Protocol (TAP)	21
4.2.3 Open Test Reporting (OTR)	23
4.2.4 Andere Formate	25
4.3 Fazit zur Evaluation der Testausgabeformate	27
5 Konzeptionierung und Umsetzung	29
5.1 Komponenten des Verfahrens	29

5.1.1	testDiscovery	30
5.1.2	test archive	31
5.1.3	testAuditor	32
5.1.4	testExecution	33
5.1.5	controller	34
5.1.6	user	34
5.2	Anforderungen an ein Testframework	34
5.3	Anforderungen an ein Projekt	35
6	Analyse der Laufzeit	36
6.1	Aufbau der Benchmark	36
6.1.1	Spezifikationen des ausführenden Systems	37
6.2	Datenerhebung der Benchmark	38
6.3	Ergebnisse der Benchmark	39
6.4	Zusammenfassung der Ergebnisse	41
7	Fazit	43
7.1	Erfüllung der Anforderungen	43
7.2	Schlussbetrachtung	44
7.3	Möglichkeiten zur Verbesserung	44
	Literaturverzeichnis	46
8	Links	47

1 Einleitung

1.1 Problemstellung

”One cannot “test quality into” a badly constructed software product, but neither can one build quality into a product without test and analysis.”

Pezzè und Young [1, S. XVII]

Jedes größere Softwareprojekt benötigt eine Vielzahl von Testfällen (nachfolgend als Testcases bezeichnet), um die Qualität der Software zu sichern. Dabei werden die einzelnen Testcases für gewöhnlich in verschiedene Klassen unterteilt (nachfolgend als Testsuites bezeichnet), die verschiedene Abschnitte der Software abdecken. Die meisten gängigen Testframeworks bieten die Möglichkeit, einzelne Testsuites und/oder Testcases gezielt auszuführen, ohne die restlichen Testcases dabei mit auszuführen.

Nehmen wir z.B. einen Entwickler, der bei einem großen Softwareprojekt die Funktionalität einer Datenbank-Schnittstelle anpasst. Testcases, welche die Funktion dieser Schnittstelle abtesten, sind hier sehr relevant. Andere Testcases, wie etwa UI-Tests oder Tests für Netzwerkverbindungen, sollten bei einem sauber modularisierten Projekt mit hoher Wahrscheinlichkeit unabhängig von Änderungen der Datenbank-Schnittstelle dasselbe Ergebnis wie vor den Änderungen des Entwicklers liefern. Da manche Testcases viel Zeit für ihre Durchführung in Anspruch nehmen, ist es sinnvoll, bei der Entwicklung nur einzelne relevante Testsuites auszuführen.

Zur Validierung des Codes muss dennoch regelmäßig jeder Testcase des Softwareprojektes durchlaufen werden, damit durch das partielle Testen des Codes keine Fehler unbemerkt im Projekt verbleiben.

Um dies zu gewährleisten, wird für gewöhnlich auf dem Build-Server nach einem Commit noch einmal die gesamte Testsuite des Projektes durchlaufen, auch wenn manche Testcases möglicherweise bereits ausgeführt wurden, ohne dass sich der Code in der Zwischenzeit geändert hat.

Diese redundanten Testausführungen verzögern den Build-Prozess des Projektes. Das führt dazu, dass die Zeit zwischen der Änderung des Codes und dem Erhalt

des Ergebnis bei steigender Anzahl und Laufzeit von Testcases immer länger wird, da für den Testlauf immer mehr Ressourcen benötigt werden. Insbesondere bei häufigen Änderungen kann sich dieser Mehraufwand erheblich auf den Entwicklungsprozess auswirken.

Es existieren zwar bereits verschiedene Ansätze zur Reduktion von Testlaufzeiten, beispielsweise durch Testselektion oder Build-Caching, diese Verfahren sind jedoch häufig an bestimmte Programmiersprachen, Build-Systeme oder Testframeworks gebunden oder optimieren einen Testlauf auf andere Art und Weise. Daraus entsteht der Bedarf nach einem möglichst frameworkunabhängigen Verfahren, das bereits vorhandene Testergebnisse wiederverwendet und ausschließlich Testcases ausführt, für die noch kein Ergebnis vorliegt, und gleichzeitig eine vollständige Testabdeckung sicherstellt.

1.2 Zielsetzung

Ziel dieser Bachelorarbeit ist die Entwicklung eines Lösungsansatzes für die folgende Fragestellung:

(Wie) Kann die Laufzeit von Testläufen unabhängig vom verwendeten Testframework durch die Wiederverwendung bereits vorhandener Testergebnisse reduziert werden, ohne die Aussagekraft der Testergebnisse zu beeinträchtigen?

Zur Beantwortung dieser Frage soll ein Verfahren entwickelt werden, welches anhand der Ergebnisse vergangener Testläufe ermittelt, für welche Testcases noch kein Ergebnis vorliegt, und ausschließlich diese Testcases ausführt. Dabei muss zwingend eine komplette Abdeckung aller Testcases erhalten bleiben. Das Ergebnis jedes Testcase muss identisch mit dem Ergebnis eines kompletten Neudurchlaufs aller Testcases sein, mit Ausnahme von Metadaten wie beispielsweise dem Zeitstempel des Testlaufs. Dabei soll die Wahl des Testframeworks möglichst keine Rolle spielen.

Zur praktischen Umsetzung des Verfahrens wird ein Prototyp mit einer beispielhaften Implementation des Verfahrens entwickelt.

Gemessen wird der Erfolg bei der Verringerung der Laufzeit des Verfahrens

anhand der Evaluation einer Benchmark in Kapitel 6, die für verschiedene Konfigurationen von Testcases folgende Kennzahlen sammelt:

- Gesamtzahl aller Testcases
- Zahl der vom Verfahren ausgeführte Testcases
- Laufzeit der Testpipeline unter Verwendung des Verfahrens
- Laufzeit der Testpipeline ohne Verwendung des Verfahrens
- Laufzeit einzelner Komponenten des Verfahrens

1.3 Begrenzung des Scope

Nicht Teil dieser Bachelorarbeit sind die folgenden Punkte:

- Überprüfung der Korrektheit von Daten:
Es wird davon ausgegangen, dass Informationen und Dateien, die dem Verfahren zur Verfügung gestellt werden, korrekt und vollständig sind.
- Aktualität von Testergebnissen:
Das Verfahren arbeitet mit Testergebnissen, die zu einem dem Verfahren unbekannten Zeitpunkt erzeugt werden. Eine Überprüfung, ob die Testergebnisse auf dem aktuellen Stand des Codes basieren, oder ob der Code oder die Testcases zwischenzeitlich geändert wurden, findet nicht statt.
- Authentizität:
Sämtliche Dateien, welche dem Verfahren von einem Projekt zur Verfügung gestellt werden, werden als legitim betrachtet. Eine Überprüfung der Authentizität oder Autorenschaft einzelner Dateien findet nicht statt.

1.4 Aufbau der Arbeit

Kapitel 2: Verwandte Themengebiete widmet sich der Einordnung dieser Bachelorarbeit in den Kontext anderer, verwandter Themengebiete, indem diese

Themen kurz vorgestellt, und in Bezug zur vorliegenden Arbeit verglichen werden.

Kapitel 3: Grundlagen und Analyse der Anforderungen beginnt mit der Analyse der Anforderungen, die ausgehend von Kapitel 1.2 an das Verfahren gestellt werden. Daraus werden die Anforderungen an ein Testausgabeformat abgeleitet. Anschließend werden die Grundlagen von reproduzierbaren Builds und der Entstehung von Testausgabeformaten beleuchtet, die für das Verständnis der folgenden Kapitel erforderlich sind.

Kapitel 4: Vergleich von Testausgabeformaten beschäftigt sich mit der Frage, welches Testausgabeformat für das Verfahren als Input infrage kommt, um die in Kapitel 3.1 gestellten Anforderungen zu erfüllen. Dazu wird in diesem Kapitel zunächst anhand des Datensatzes untersucht, welche Testausgabeformate in welchem Umfang verbreitet sind. Anschließend werden die verbreitetsten Formate genauer analysiert und auf ihre Eignung für das Verfahren untersucht. Das Kapitel endet mit der begründeten Entscheidung für ein Format.

In **Kapitel 5: Konzeptionierung und Umsetzung** wird das Verfahren unter Berücksichtigung der Ergebnisse aus Kapitel 4 konzeptionell erläutert. Die einzelnen Komponenten des Verfahrens sowie ihr Zusammenspiel werden im Detail erklärt. Anschließend werden die daraus resultierenden Anforderungen erfasst, die an ein Testframework und ein Projekt, in welches das Verfahren integriert werden kann, gestellt werden.

Kapitel 6: Analyse der Laufzeit präsentiert die Ergebnisse der Benchmark, und analysiert anhand dieser Ergebnisse das Laufzeitverhalten des Verfahrens und einzelner Komponenten in verschiedenen Konfigurationen im Vergleich zu einem konventionellen Durchlauf.

Kapitel 7: Fazit schließt diese Bachelorarbeit mit einer Zusammenfassung der Ergebnisse, einer Analyse, inwieweit das Verfahren die eingangs gestellten Anforderungen erfüllen konnte, und einer Diskussion möglicher Verbesserungen des Verfahrens.

2 Verwandte Themengebiete

Das Thema dieser Bachelorarbeit weist Überschneidungen mit mehreren artverwandten Themengebieten auf, die eine ähnliche Zielsetzung verfolgen. Die hier vorgestellten Verfahren benutzen ebenfalls Techniken, um die Zahl der auszuführenden Testcases oder zu erzeugenden Ausgaben sinnvoll zu reduzieren, unterscheiden sich jedoch von dem hier entwickelten Verfahren durch die konkrete Umsetzung, der betrachteten Informationen, dem Grad der Framework-Agnostik oder dem Endresultat.

2.1 Test Impact Analysis (TIA)

Test Impact Analysis bezeichnet Verfahren, die anhand des bestehenden Codes des Projekts analysieren, welche Testcases durch Änderungen am Code betroffen sein können. Als Grundlage dieser Analyse können beispielsweise interne Abhängigkeiten von Dateien oder Programmabschnitten dienen.

Auch wenn TIA ähnlich wie das in dieser Bachelorarbeit entwickelte Verfahren ermittelt, welche Teilmenge aller Testcases ausgeführt werden soll, unterscheiden sich TIA und das hier entwickelte Verfahren in ihrer Entscheidungsgrundlage: Während TIA sich auf die Analyse des vorhandenen Codes konzentriert, beschränkt sich das vorliegende Verfahren auf die Ergebnisse von Testausgaben. Außerdem liegen nach Ablauf des vorliegenden Verfahrens die Ergebnisse für allen Testcases vor, da alle Testcases ausgeführt werden, für die noch kein Ergebnis vorhanden ist. Bei TIA werden dagegen nur die Testcases erneut ausgeführt, die als möglicherweise von den Codeänderungen betroffen eingestuft werden. Für die übrigen Testcases wird im betrachteten Testlauf kein neues Ergebnis erzeugt.

Das allgemeine Konzept der TIA ist nicht an eine spezielle Programmiersprache oder ein bestimmtes Testframework gebunden. Konkrete Implementierungen hängen jedoch von der spezifischen Struktur der Dateien und des Codes innerhalb eines Projekts ab.

2.2 Regression Test Selection (RTS)

Regression Test Selection bezeichnet Verfahren, die anhand bestimmter zuvor festgelegter Kriterien abschätzen, welche Untermenge aller Testcases ausgeführt werden soll. Dabei kann unter anderem die zuvor beschriebene Test Impact Analysis als ein mögliches Entscheidungskriterium dienen.

Wie auch TIA zielt RTS nicht zwingend auf die erneute Ausführung sämtlicher Testcases ab, sondern versucht, eine für die untersuchte Änderung geeignete Teilmenge auszuwählen. Ein RTS-Verfahren wird als sicher bezeichnet, wenn es keinen Testcase ausschließt, der durch die vorgenommenen Änderungen beeinflusst wurde. Ob diese Sicherheit erreicht wird oder ob gewisse Unsicherheiten in Kauf genommen werden, um eine zusätzliche Reduktion der Laufzeit zu erzielen, ist von der jeweiligen Implementation der RTS abhängig.

Das in dieser Arbeit entwickelte Verfahren entscheidet zwar ebenfalls, welche Testcases ausgeführt werden sollen, bezieht sich dabei aber auf die empirisch erfassbaren Daten aus den Ergebnissen der vorherigen Testläufe, statt auf eine Abschätzung der Auswirkungen der Änderungen am Code. Außerdem wird im Gegensatz zu RTS die Auswertung aller Testcases als Ziel gesetzt.

RTS ist wie auch TIA auf konzeptioneller Ebene nicht zwingend an ein bestimmtes Testframework gebunden. Allerdings ist die Analyse der Daten stark vom verwendeten Testframework abhängig. Diese Ebene kann jedoch grundsätzlich durch Adapter abstrahiert werden, um einen frameworkunabhängigen Kern für RTS zu schaffen.

Diesem Prinzip folgt auch das in dieser Arbeit entwickelte Verfahren: Wie später in Kapitel 5.1 dargestellt, sind einzelne Komponenten des Verfahrens vom verwendeten Framework abhängig. Die zentrale Ermittlung der auszuführenden Testcases ist dagegen frameworkunabhängig aufgebaut.

2.3 Build Caching

Build Caching bezeichnet die Speicherung der durch vorherige Builds erzeugten Artefakte, damit diese bei späteren Builds wiederverwendet werden können.

Dazu wird für einen Build üblicherweise ein Cache-Schlüssel aus den deklarierten Eingaben und seiner Implementierung gebildet. Ist für diesen Schlüssel bereits ein Ergebnis vorhanden, kann das Buildsystem die gespeicherten Dateien übernehmen, anstatt sie wie sonst üblich bei jedem Build neu zu erzeugen.

Build Caching und das in dieser Arbeit entwickelte Verfahren beruhen auf einer ähnlichen Idee: Ein bereits vorliegendes Ergebnis soll nicht erneut berechnet werden, um Laufzeit einzusparen.

Ein wesentlicher Unterschied besteht allerdings in der Natur der wiederverwendeten Dateien: Beim Build Caching sind es Artefakte des Builds, beim hier vorgestellten Verfahren sind es die Ausgaben von vorherigen Testläufen.

Eine weitere Gemeinsamkeit besteht in der Wichtigkeit von reproduzierbaren Entwicklungsumgebungen: Beim Build Caching müssen die Entwicklungsumgebungen von zwei Build-Läufen identisch sein, um die Artefakte des vorherigen Laufs übernehmen zu können. Beim hier entwickelten Verfahren ist eine identische Entwicklungsumgebung sogar eine Voraussetzung, um die Aussagekraft des Verfahrens durch die Verwendung von Ergebnissen aus einem vorherigen Lauf nicht einzuschränken.

Damit ist Build Caching zwar nicht vom verwendeten Testframework, allerdings vom jeweiligen Buildsystem abhängig.

Da sich keiner dieser Ansätze direkt mit dem Erreichen von Frameworkunabhängigkeit eines Verfahrens durch Testausgabeformate befasst, wird diesem Thema in dieser Arbeit eine besondere Aufmerksamkeit gewidmet.

Das entwickelte Verfahren stellt dabei keinen Ersatz für TIA, RTS oder Build Caching dar, sondern einen ergänzenden Ansatz zur weiteren Optimierung von Testläufen.

3 Grundlagen und Analyse der Anforderungen

In diesem Kapitel werden die Anforderungen an das Verhalten des Verfahrens, die sich aus Kapitel 1.2 ergeben, näher erörtert.

Ebenso werden Grundlagen sowie Anforderungen bezüglich der Testausgabeformate vorgestellt.

3.1 Anforderungen an das Verfahren

Folgende Anforderungen werden an einen Durchlauf des Verfahrens gestellt:

- **Die Wahl der verwendeten Testframework(s) ist unerheblich**
Das Verfahren soll framework-agnostisch funktionieren, auch wenn innerhalb des Projektes verschiedene Testframeworks zum Einsatz kommen.
- **Nach Abschluss des Verfahrens wurde jeder Testcase für den aktuellen Stand des Codes mindestens einmal durchgeführt**
Testcases können vor Durchlauf des Verfahrens mehrfach ausgeführt worden sein, allerdings darf während des Verfahrens selbst kein Testcase ausgeführt werden, der bereits ausgeführt wurde, um die Laufzeit der Testphase so gering wie möglich zu halten. Trotzdem muss die gesamte Testsuite komplett abgedeckt sein, um die Aussagekraft des Testlaufes im Vergleich zu einem komplett neuen Durchlauf nicht zu beeinträchtigen.
- **Die Ausgabe des durch das Verfahren ausgeführten Testlaufs ist auf dieselbe Weise verfügbar, wie die anderen Ausgaben**
Die Ausgabe soll in demselben Format, auf dieselbe Art und Weise abgelegt werden, wie auch die anderen Ausgaben, die dem Verfahren zur Verfügung gestellt werden.
- **Die Laufzeit eines Testdurchlaufs unter Verwendung des Verfahrens ist kleiner oder gleich der Laufzeit eines konventionellen Durchlaufs**

Das Verfahren soll die Gesamtlaufzeit der Testausführung reduzieren.

3.2 Anforderungen an ein Testausgabeformat

Um ein framework-agnostisches Verfahren zu ermöglichen, muss ein testframework-agnostisches Testausgabeformat gefunden werden, in welchem die Ergebnisse eines Testlaufs in einer standardisierten Form festgehalten werden.

`testAuditor` ist der Kern des Verfahrens, und benötigt zur korrekten Funktion Zugriff auf die Gesamtheit aller Testcases, sowie Informationen über den Status von bereits gelaufenen Testcases. Eine detailliertere Beschreibung von `testAuditor` findet sich in Kapitel 5.1.3.

Mit Blick auf diese, sowie die unter Kapitel 3.1 beschriebenen Anforderungen an das Verfahren, würde ein ideales Testausgabeformat sämtliche hier gestellten Anforderungen erfüllen:

Ein ideales Ausgabeformat für Tests:

- **ermöglicht die vollständige Ermittlung aller im Projekt vorhandenen Testcases**

Dieser Punkt ist essenziell, zum einen damit `testAuditor` eine Aussage darüber treffen kann, ob eine vollständige Abdeckung aller Testcases erzielt wurde, zum anderen muss `testAuditor` zum Erzielen einer vollständigen Abdeckung potentiell auf jeden vorhandenen Testcase zugreifen können. Dazu muss `testAuditor` selbstverständlich auch jeder Testcase innerhalb des Projektes bekannt sein.

- **identifiziert jeden Testcase eindeutig**

Je nach Testframework und Implementierung können mehrere Testcases denselben Namen besitzen, sofern sie sich in unterschiedlichen Namespaces oder Kontexten befinden. Das Ausgabeformat muss daher eine eindeutige Zuordnung zwischen den einzelnen Testcases und ihren jeweiligen Ergebnissen ermöglichen.

- **sagt für jeden Testcase einzeln aus, ob er ausgeführt wurde oder nicht**

Dieser Punkt setzt die Erfüllung der ersten beiden Punkte voraus. Zusätzlich muss aus dem Eintrag eines Testcases im Ausgabeformat erkennbar sein, ob der Test ausgeführt worden ist.

- **ist ein strukturiertes Format**

Es muss eine erfassbare Struktur für das Testausgabeformat vorhanden sein, damit ein entsprechender Parser für `testAuditor` entwickelt werden kann.

- **ist in vielen Frameworks über viele Programmiersprachen hinweg vertreten**

Es ist kaum realistisch anzunehmen, dass ein strukturiertes Format existiert, welches von jedem existierenden Testframework gleichermaßen benutzt wird. Dennoch gibt es durchaus gängige Formate, die von unterschiedlichen Testframeworks aus unterschiedlichen Sprachen unterstützt werden, wie folgend in Kapitel 4 untersucht wird.

3.3 Reproduzierbare Builds - 'it works on my machine'

Damit in dem hier vorgestellten Verfahren eine qualifizierte Aussage über die Testergebnisse getroffen werden kann, muss gewährleistet sein, dass alle Testcases unabhängig vom ausführenden System immer dasselbe Testergebnis liefern. Beispielsweise muss ein Testcase, der auf der Maschine eines Entwicklers ein bestimmtes Ergebnis liefert, auch zwingend auf einem Build-Server dasselbe Ergebnis liefern. Andernfalls könnte eine Diskrepanz zwischen den Testergebnissen zu einer verfälschten Aussage des Verfahrens über den aktuellen Stand der Tests führen.

Im Rahmen dieser Bachelorarbeit wird hierfür der Linux-packagemanager `Nix` benutzt. `Nix` bietet die Funktionalität, die Entwicklungsumgebung deklarativ zu beschreiben, indem benötigte Abhängigkeiten in einer sogenannten `flake` festgelegt werden. Eine dazugehörige Datei `flake.lock` enthält dann detaillierte Informationen über den Build. Dadurch können auf verschiedenen Systemen identische Entwicklungsumgebungen aufgebaut werden.

Es gilt zu beachten, dass durch diesen Aufbau nur explizit deklarierte interne Abhängigkeiten deterministisch erfasst werden können. Externe Faktoren wie etwa Netzwerkschnittstellen, zufallbasierte Ereignisse oder Ähnliches können auf diese Weise nicht reproduzierbar festgehalten werden.

Ein vollständige Garantie des Reproduzierbarkeit zwischen Systemen ist nur schwer zu erreichen, jedoch bietet Nix in diesem Fall eine ausreichende Grundlage.

3.4 Entstehung eines Testausgabeformats

Um zu verdeutlichen, wie die finale Form eines Testausgabeformates entsteht, wird in diesem Kapitel näher auf die Faktoren eingegangen, welche die genaue Struktur und das finale Aussehen des Testausgabeformates beeinflussen. Die Form eines Testausgabeformates hängt im Wesentlichen von den folgenden Faktoren ab, deren Aufteilung der von Winkler, Hametner und Biffel [2] vorgestellten Struktur eines Testframeworks folgt:

- **verwendetes Testframework:**

Das verwendete Testframework ist für gewöhnlich an jedem Schritt der Testgenerierung beteiligt und erfüllt die Rolle eines Managers der einzelnen Komponenten. Daher bestimmt es je nach konkretem Framework stärker oder schwächer die Verwendung der folgenden Punkte:

- **Struktur der zugrunde liegenden Testdateien:**

Die (Nicht-)Verwendung von Klassen, Testsuites oder anderen vom Testframework oder der Programmiersprache bereitgestellten Optionen zur Organisation der Testcases, sowie die Dateistruktur der Testdateien können einen Einfluss auf das Endresultat haben.

- **Test Runner:**

Auch als *Scheduler*, *Harness* oder *Orchestrator* bezeichnet, beschreibt der Begriff "Test Runner" hier die Komponente eines Testframeworks, welche die Testcases ausführt und die Ergebnisse an den Test Reporter weiterreicht. Der Test Runner beeinflusst u.a. die Darstellung von Ereignissen, die während des Testlaufs auftreten und in die Ausgabe übernommen werden.

- **Test Reporter:**

Auch als *test generator* bezeichnet, beschreibt "Test Reporter" hier jene Komponente eines Testframeworks, welche aus dem vom Test Runner bestimmten Ergebnis der Testsuite die menschen- bzw. maschinenlesbare Ausgabe generiert.

- **verwendetes Testausgabeformat:**

Damit ist sowohl das Dateiformat, als auch die Wahl eines strukturierten Ausgabeformats gemeint. Näheres dazu in Kapitel 4.

In den meisten Testframeworks übernimmt das Testframework selbst die Aufgaben des Test Runners und des Test Reporters, doch in manchen Fällen werden diese Komponenten aber auch durch andere Prozesse bereitgestellt. Dies ist zum Beispiel in der Programmiersprache Java der Fall: Hier stellen die beiden build-tools Maven und Gradle jeweils ihre eigenen Test Runner bzw. Test Reporter zur Verfügung, was unterschiedliche Kombinationen aus Testframework, Test Runner und Test Reporter erlaubt. Dass dies auch zu Unterschieden in der Testausgabe führen kann, ist in Codeblock 3.1 dargestellt.

JUnit5, Jupiter:

```
<?xml version="1.0" encoding="UTF-8"?>
<testsuite name="JUnit Jupiter" tests="5" skipped="1" failures="1"
  errors="0" time="0.036" hostname="DESKTOP-I9APALO"
  timestamp="2026-07-04T00:45:01">
<properties>
<property name="file.encoding" value="UTF-8"/>
<property name="file.separator" value="/" />
...
<testcase name="test_neg()" classname="BasicTest" time="0.006">
```

JUnit5, Jupiter mit Maven surefire:

```
<?xml version="1.0" encoding="UTF-8"?>
<testsuite xmlns:xsi="http://www.w3.org/2001/XMLSchema-instance"
  xsi:noNamespaceSchemaLocation=
"http://maven.apache.org/surefire/.../surefire-test-report.xsd"
  version="3.0.2" name="BasicTest" time="0.013" tests="4"
  errors="0" skipped="1" failures="1">
```

```
<properties>
  <property name="java.specification.version" value="21"/>
  <property name="sun.jnu.encoding" value="UTF-8"/>
  ...
  <testcase name="test_neg" classname="BasicTest" time="0.0"/>
  ...
JUnit5, Jupiter mit Gradle test task:
<?xml version="1.0" encoding="UTF-8"?>
<testsuite name="BasicTest" tests="4" skipped="1" failures="1"
  errors="0" timestamp="2026-07-03T22:47:00.701Z"
  hostname="DESKTOP-I9APALO" time="0.009">
  <properties/>
  <testcase name="test_neg()" classname="BasicTest" time="0.001"/>
  ...
```

Codeblock 3.1: direkter Vergleich von JUnit XML, erzeugt durch JUnit5 mit Jupiter in Java. Jeder Ausgabe liegen dieselben beiden Testdateien zugrunde.
"..." bezeichnet gekürzte Stellen.

Obwohl für jede Ausgabe JUnit5 mit Jupiter als Testframework benutzt wird, jede Ausgabe JUnit XML als Format aufweist, und jede Ausgabe auf denselben beiden Testdateien basiert, gibt es durch die unterschiedlichen Test Runner und Test Reporter deutliche Unterschiede in der Testausgabe.

So ignoriert Gradle beispielsweise in diesem exemplarischen Fall das Element `<properties>`, während Maven und Jupiter (ohne build-tool) eine exzessive Liste von `<property>` in der Testausgabe mitgeben.

Auch die Benennung der Testcases unterscheidet sich:

Jupiter und Gradle behalten den Namen `test_neg()` bei, so wie er auch in der Testdatei verwendet wird, während Maven den Namen zu `test_neg` kürzt.

Ähnliches bei der Benennung der Testsuite: Da Gradle und Maven für jede Datei eine eigene Ausgabedatei erzeugen, benutzen die beiden build-tool den Namen der jeweiligen Testsuite, hier "BasicTest", als Wert des Attributes "name" im Element `<testsuite>`. Jupiter gibt dagegen nur eine Ausgabedatei aus, die das Ergebnis aller Testdateien enthält, und benutzt in dieser den Standardwert "JUnit Jupiter" als Namen für `<testsuite>`.

Es ist somit ersichtlich, dass die konkrete Struktur einer Testausgabe nicht allein durch das verwendete Testframework oder das gewählte Testausgabeformat bestimmt wird. Vielmehr entsteht diese durch das Zusammenwirken in diesem Kapitel beschriebenen Komponenten. Selbst bei identischem Testframework, Ausgabeformat und zugrunde liegenden Testdateien können sich die erzeugten Ausgaben hinsichtlich ihrer Struktur, ihrer Benennung und der enthaltenen Informationen unterscheiden.

Dieser Sachverhalt muss in Kapitel 4 bei der Bewertung der Struktur der einzelnen Testausgabeformate berücksichtigt werden.

4 Vergleich von Testausgabeformaten

Um das Tool `testAuditor` zu entwickeln, welches framework-agnostisch eingesetzt werden kann, muss `testAuditor` die Ausgabe eines Testlaufes unabhängig vom verwendeten Framework parsen können. Die Anforderungen an ein Testausgabeformat wurden bereits in Kapitel 3.2 untersucht.

Standardmäßig geben die meisten Testframeworks das Ergebnis eines Testlaufs in einem unstrukturierten Format über die Konsole aus. Allerdings bieten fast alle etablierten Testframeworks auch eine Auswahl an Dateiformaten an, über welche die Testausgabe ebenfalls präsentiert werden kann.

Für diese Dateiformate wurden über die Jahre einige framework-übergreifende Ausgabeformate entwickelt, die sich in unterschiedlicher Ausprägung durchsetzen konnten.

Es gilt nun, ein geeignetes Testausgabeformat zu finden, welches von `testAuditor` als Quelle für Testergebnisse genutzt werden kann.

4.1 Evaluation des Datensatzes

4.1.1 Methodik

Aufgrund der Vielzahl von verschiedenen Testframeworks und der Vielfältigkeit ihrer Ausgabeformate können im Rahmen dieser Bachelorarbeit nur die verbreitetsten Formate untersucht werden.

Zur Untersuchung der praktischen Umsetzung einzelner Formate und zur exemplarischen Erfassung ihrer Verbreitung wird ein stichprobenartiger Datensatz betrachtet. Dabei gilt zu beachten, dass dieser Datensatz nur eine kleine Menge ausgewählter Programmiersprachen umfasst. Außerdem beschränken sich die untersuchten Testframeworks auf die am weitesten verbreiteten in ihrer jeweiligen Sprache, um die Etablierung von Testausgabeformaten möglichst praxisnahe darstellen zu können. Außerdem bieten länger etablierte Testframeworks erfahrungsgemäß eine breitere Auswahl von Testausgabeformaten, als weniger verbreitete oder neue Testframeworks.

Bei der Untersuchung von Plugins für zusätzliche Testausgabeformate wurden ausschließlich Plugins berücksichtigt, welche über den hier benutzten Package-

manager `Nix` bereitgestellt werden. Würden externe Plugins, welche zumeist aus unabhängig gepflegten Repositorien stammen, ebenfalls betrachtet werden, würde die Zahl der unterstützten Testausgabeformate bei den meisten untersuchten Testframeworks deutlich steigen. Da keine Aussage über die Vertrauenswürdigkeit und Qualität der externen Plugins getroffen werden kann, beschränkt sich diese Untersuchung auf von `Nix` bereitgestellte Plugins.

4.1.2 Struktur der Testdateien

Die Struktur der Testdateien wird für jede untersuchte Programmiersprache soweit möglich einheitlich gehalten.

Es existieren zwei Testdateien. Sofern das Testframework die Möglichkeit bieten, besitzt jede der Dateien ihren eigenen Namespace. Die Bezeichnung der Namespaces kann variieren, da manche Testframeworks eine bestimmte Namenskonvention voraussetzen.

In der ersten Datei liegen 4 Testcases im Namespace `BasicTest`:

- `test_neg()`: Ein einfacher negativer Testcase, der eine korrekte Assertion beinhaltet und nicht fehlschlägt.
- `test_pos()`: Ein einfacher positiver Testcase, der eine falsche Assertion beinhaltet und fehlschlägt.
- `test_skip()`: Ein Testcase, der übersprungen wird. Für gewöhnlich werden übersprungene Testcases trotzdem in der Testausgabe aufgeführt, mit der zusätzlichen Information, dass dieser Testcase übersprungen wurde, anstelle eines Ergebnisses.
- `test_same_name()`: Ein einfacher Testcase, der eine korrekte Assertion beinhaltet und nicht fehlschlägt. In der zweiten Datei existiert ein Testcase mit demselben Namen.

In der zweiten Datei liegt ein Testcase im Namespace `BasicTest2`:

- `test_same_name()`: Ein einfacher Testcase, der eine korrekte Assertion beinhaltet und nicht fehlschlägt. In der ersten Datei existiert ein Testcase

mit demselben Namen.

`test_same_name` untersucht, ob es allein aus der Testausgabe heraus möglich ist, einen Testcase eindeutig zu identifizieren, auch wenn in unterschiedlichen Namespaces verschiedene Testcases demselben Namen aufweisen.

Tabelle 1 zeigt die Ergebnisse der Untersuchung des Datensatzes zur Verbreitung von Testausgabeformaten:

Framework	Sprache	JUnit XML	XML (anderes)	OTR	TAP	JSON	HTML
catch2	C++	✓	✓	✗	✓	✗	✗
doctest	C++	✓	✓	✗	✗	✗	✗
gtest	C++	✓	✗	✗	✗	✓	✗
hspec	Haskell	~	✗	✗	✗	✗	✗
tasty	Haskell	~	✗	✗	~	✗	✗
junit5/jupiter	Java	✓	✗	✓	✗	✗	✗
junit5/jupiter (maven surefire)	Java	✓	✗	~	✗	✗	~
junit5/jupiter (gradle test task)	Java	✓	✗	~	✗	✗	✓
behat	PHP	✓	✗	✗	✗	✓	✗
codeception	PHP	✓	✗	✗	✗	✗	✓
phpunit	PHP	✓	✗	✓	✗	✗	✓
pytest	Python	✓	✗	✗	~	~	~
unittest	Python	✓	✗	✗	✗	✗	✗
Von insgesamt 13 (Support nativ oder per Plugin)		13	2	4	3	3	5

✓

 Nativ unterstützt

~

 Über Plugins unterstützt

✗

 Nicht offiziell unterstützt

Tabelle 1: Übersicht der Verbreitung bestimmter Formate. Sofern nicht anders angegeben, werden die vom jeweiligen Testframework bereitgestellten Test Runner / Test Reporter benutzt.

4.2 Evaluation der häufigsten Formate

In diesem Kapitel werden die häufigsten frameworkübergreifend verwendeten Testausgabeformate kurz vorgestellt und nach den in Kapitel 3.2 festgesetzten Kriterien auf ihre Eignung als Input für `testAuditor` evaluiert.

4.2.1 JUnit XML

Übersicht

JUnit XML ist ein XML-basiertes Format, welches ursprünglich für das Java-Testframework JUnit entwickelt wurde. Für JUnit XML existiert kein einheitlicher Standard, dass heißt, es existiert auch kein beschreibendes XSD-Schema, wie sonst für XML-Formate üblich. Trotzdem wurde JUnit XML von vielen Testframeworks in gleicher oder ähnlicher Form adaptiert, wie es ursprünglich für JUnit entworfen wurde. Außerdem existieren viele weitere Schnittstellen zwischen JUnit XML und anderen für das Software-Testing relevanten Programme, beispielsweise viele CI/CD-Systeme. Auf diese Weise hat sich JUnit XML zum häufigsten benutzen Testausgabeformat für Testframeworks entwickelt.

Struktur

Wie bereits erwähnt gibt es bei JUnit XML kein standardisiertes Schema. Allerdings hat sich eine Grundstruktur durchgesetzt, die von nahezu allen Testframeworks, welche JUnit XML als Testausgabeformat anbieten, verwendet wird. Ein typisches Beispiel für diese Grundstruktur ist Codeblock 4.1:

```
<?xml version="1.0" encoding="UTF-8"?>
<testsuites name="default">
  <testsuite name="Basic tests" file= "features/basic.feature"
    tests="4" skipped="0" failures="2" errors="0" time="0.006">
    <testcase name="test_neg" classname="Basic tests"
      status="passed" time="0.004" file="features/basic.feature"
      line="4"></testcase>
    ...
  </testsuite>
</testsuites>
```

Codeblock 4.1: JUnit XML, erzeugt durch das PHP-Testframework behat.
"..." bezeichnet gekürzte Stellen.

Das Wurzel-Element `<testsuites>` enthält eine Menge von Elementen mit der Bezeichnung `<testsuite>`, welche jeweils eine Menge von Elementen mit der Bezeichnung `<testcase>` enthalten. Jedes `<testcase>` repräsentiert einen Testcase aus der ursprünglichen Testsuite des zu testenden Programms und enthält für gewöhnlich Informationen über das Testergebnis, den Ablauf und den ursprünglichen Testcase. Hier ist allerdings wieder wichtig zu erwähnen, dass der Inhalt dieses Elements ebenso wenig standardisiert ist, wie der Inhalt der übrigen Elemente. Deutlich wird dieser Sachverhalt in Codeblock 4.2. Unterschiede in der grundlegenden Struktur zeigen sich z.B. in Codeblock 4.3. Hier wird das Element `<testsuite>` verschachtelt verwendet, statt wie sonst üblich nur einmal.

```
JUnit5 (maven), Java:
<testcase name="test_neg" classname="BasicTest" time="0.012"/>

PHPUnit, PHP:
<testcase name="test_neg" file="/home/.../test.php" line="7"
    class="BasicTest" classname="BasicTest" assertions="1"
    time="0.000645"/>

gtest, C++:
<testcase name="test_neg" file="./test/gtest/test.cpp" line="3"
    status="run" result="completed" time="0."
    timestamp="2026-06-29T22:44:17.561" classname="BasicTests" />
```

Codeblock 4.2: direkter Vergleich verschiedener Implementierungen des `<testcase>`-tags in ausgewählten JUnit-XML Ausgaben. Verglichen wird jeweils die Ausgabe des fehlerlos ausgeführten Testcases `test_neg`.
"..." bezeichnet gekürzte Stellen.

```
<?xml version='1.0'?>
<testsuites errors="0" failures="1" tests="5" time="0.001">
  <testsuite name="AllTests" tests="5">
    <testsuite name="Test1" tests="4">
      <testcase name="test_neg" time="0.000"
        classname="AllTests.Test1" />
      ...
    
```

Codeblock 4.3: JUnit XML, erzeugt durch das Haskell-Testframework `tasty` mit dem `ant`-Plugin.
"..." bezeichnet gekürzte Stellen.

Aus Codeblock 4.2 ist ersichtlich, dass sich die benutzten Attribute von `<testcase>` sowie deren Inhalt stark unterscheiden können. Jedoch werden zwei bestimmte Attribute von den meisten Testframeworks gesetzt und auch in gleicher Weise verwendet:

- `name=""` enthält den Namen des Testcase
- `classname=""` enthält die Bezeichnung des Namespaces bzw. der Klasse oder Gruppe des Testcase

Dieser Trend aus Codeblock 4.2 setzt sich auch in den übrigen im Datensatz untersuchten JUnit XML Ausgaben fort. Es gibt zwar einige wenige Ausnahmen wie exemplarisch in Codeblock 4.4 dargestellt, diese sind jedoch eher selten. Eine ausführliche Übersicht darüber, wie häufig die eindeutige Zuordnung zwischen Testergebnis und Testcase durch die Attribute `name` und `classname` möglich ist, ist in Tabelle 2 zu finden.

```
<testcase name="test_neg" class="BasicTest"
  file="/home/.../Test.php" time="0.000252" assertions="1"/>
```

Codeblock 4.4: JUnit XML für den Testcase `test_neg`, erzeugt durch das PHP-Testframework codeception. Codeception benutzt statt des häufig verwendeten Attribut `"classname"` das Attribut `"class"`.
"`...`" bezeichnet gekürzte Stellen.

Verbreitung

Da JUnit XML ursprünglich spezifisch für das Testframework JUnit entwickelt wurde, folgt die grundlegende Struktur den Gegebenheiten und Anforderungen dieses Frameworks. Zwar folgen viele weitere Testframeworks auch in anderen Sprachen einer ähnlichen Struktur oder können die JUnit XML Struktur trotz einiger Unterschiede benutzen, in einzelnen Fällen kommt es jedoch zu Schwierigkeiten und ungewöhnlichen Anpassungen der XML-Struktur.

Abgesehen davon ist JUnit XML das einzige Testausgabeformat, welches von jedem im Datensatz untersuchten Testframework ausgegeben werden kann. Dies erfolgt zumeist sogar nativ, vereinzelt muss die Unterstützung erst über offiziell

Framework	Sprache	Zuordnung über name+classname	Zuordnung über alternative Attribute	Namen der alternativen Attribute
Catch2	C++	✓	~	~
doctest	C++	✓	~	~
gtest	C++	✓	~	~
hspec	Haskell	✓	~	~
tasty	Haskell	✓	~	~
JUnit5	Java	✓	~	~
JUnit5	Java (Maven)	✓	~	~
JUnit5	Java (Gradle)	✓	~	~
Behat	PHP	✓	~	~
codeception	PHP	✗	✓	name+class
PHPUnit	PHP	✓	~	~
pytest	Python	✓	~	~
unittest	Python	✓	~	~

- ✓ Eindeutige Zuordnung möglich
- ~ nicht notwendig
- ✗ Eindeutige Zuordnung nicht möglich

Tabelle 2: Übersicht zur eindeutigen Zuordnung des Testergebnis zum ursprünglichen Testcase über Attribute in JUnit XML

unterstützte Plugins hinzugefügt werden.

Fazit zu JUnit XML

Aufgrund der weiten Verbreitung und trotz der fehlenden Standardisierung ähnlichen Umsetzung in vielen Testframeworks ist JUnit XML ein geeigneter Input für `testAuditor`, da es in der Praxis trotz einiger potentieller Fehlerquellen mit einer Vielzahl von Testframeworks kompatibel ist.

4.2.2 Test Anything Protocol (TAP)

Übersicht

Das Test Anything Protocol wurde ursprünglich für die Programmiersprache Perl entworfen, wurde über die Jahre hinweg jedoch auch für Testframeworks in anderen Sprachen weiterentwickelt und integriert. Anders als bei JUnit XML wird für TAP eine Spezifikation bereitgestellt und gepflegt, siehe [3]. Anders als die meisten anderen hier untersuchten Testausgabeformate ist TAP keine spezialisierte Struktur eines bereits bestehenden Dateiformates, sondern ein

eigenständiges textbasiertes Ausgabeformat.

Struktur

Ein TAP-Dokument enthält eine Zeile, welche die Gesamtzahl aller Testcases angibt, entweder zu Beginn oder am Ende des Dokumentes. Dazu kommt eine Auflistung der Testergebnisse mit optionalen Zusatzinformationen, zumeist der Name des Testcase. Übersprungene Tests können über zusätzliche "Directives" gekennzeichnet werden.

Da die meisten Zusatzinformationen optional sind, zeigt Codeblock 4.5 bereits eine vollständig gültige, minimale TAP-Datei:

```
TAP version 14
1..1
ok
```

Codeblock 4.5: Minimales TAP-Beispiel

Eine solche Darstellung ist natürlich ungeeignet, da so keine Zuordnung zwischen Testergebnis und Testcase möglich ist. In der Praxis kann dieser Zusammenhang allerdings durch die optionalen Zusatzinformationen hergestellt werden, wie beispielhaft mit pytest in Codeblock 4.6 demonstriert:

```
# TAP results for test/pytest/test.py
ok 1 test/pytest/test.py::test_neg
not ok 2 test/pytest/test.py::test_pos
...
ok 3 test/pytest/test.py::test_skip # SKIP ...
ok 4 test/pytest/test.py::test_same_name
1..4
```

Codeblock 4.6: TAP, erzeugt durch pytest.
"..." bezeichnet gekürzte Stellen.

Eignung

Eine eindeutige Zuordnung zwischen Testergebnis und Testcase ist nicht in allen untersuchten Testframeworks, die TAP als Ausgabeformat bieten, möglich. Als

Beispiel dient Catch2: Zwei Testcases dürfen in diesem Framework denselben Namen aufweisen, solange sie mit unterschiedlichen Labels versehen sind. Diese Zusatzinformationen sind allerdings nicht zwingend im TAP-Format erforderlich und werden vom Catch2-Reporter schlicht nicht übernommen. Dies kann eine Ausgabe wie in Codeblock 4.7 zur Folge haben, bei der zwei Testergebnisse mit demselben Namen bezeichnet werden:

```
...  
# test_same_name  
not ok 3 - false  
# test_same_name  
ok 4 - true  
...
```

Codeblock 4.7: TAP, erzeugt durch catch2.
"..." bezeichnet gekürzte Stellen.

Dies macht TAP in diesem Fall als Ausgabeformat ungeeignet. Andere Testframeworks wie beispielsweise pytest oder tasty sorgen allerdings für eine eindeutige Zuordnung in ihren jeweiligen Ausgaben.

Fazit zu TAP

TAP ist aufgrund seiner sehr geringen Minimalstruktur und vor allem wegen seiner nur mäßigen Verbreitung eher nicht als Input für `testAuditor` geeignet.

4.2.3 Open Test Reporting (OTR)

Übersicht

Open Test Reporting (OTR) wird von demselben Entwicklerteam, das auch hinter dem Framework JUnit und damit auch hinter der ursprünglichen Version von JUnit XML steht, als Nachfolger von eben diesem entwickelt. Das Entwicklerteam verfolgt dabei laut eigenen Aussagen das Ziel, mit OTR die historisch gewachsenen Probleme von JUnit XML (siehe Kapitel 4.2.1) zu umgehen. OTR soll nach den Vorstellungen der Entwickler auf lange Sicht den Platz von JUnit XML als häufigstes Ausgabeformat für Testläufe einnehmen. [4]

OTR ist ein standardisiertes XML-basiertes Format. OTR unterscheidet dabei zwischen zwei Strukturen: Hierarchisch und eventbasiert. Beide Strukturen nutzen dasselbe Set von Kernelementen, unterscheiden sich aber in ihrer Struktur. Für beide Strukturen gibt es programmiersprachenspezifische Erweiterungen.

Ausgehend von einer OTR-XML Ausgabe kann auch eine OTR-spezifische HTML-Ausgabe erzeugt werden.

Struktur

Für diese Untersuchung wird nur die eventbasierte XML-Struktur betrachtet, da diese Struktur das von den im Datensatz untersuchten Testframeworks benutzte Format ist.

Im eventbasierten Format werden die Ergebnisse nicht wie in JUnit XML oder TAP durch ein einzelnes Element mit optionalen Attributen repräsentiert, sondern über verschiedene Elemente, welche jeweils das Ergebnis eines Event der Testausführung enthalten. Demonstriert wird diese Struktur in Codeblock 4.8:

```
...
<e:started id="3" parentId="2" name="test_neg"
    time="2026-06-25T14:11:44.985961Z">
...
<e:finished id="3" time="2026-06-25T14:11:44.986266Z">
...
```

Codeblock 4.8: OTR von `test_neg`, erzeugt durch PHPUnit.
"..." bezeichnet gekürzte Stellen.

Hierbei enthält das Element `<e:started>` Informationen über den Testcase aus der ursprünglichen Testdatei, während `<e:finished>` Informationen über das Ergebnis des Testlaufs enthält.

Wie auch in JUnit XML und TAP sind die meisten Informationen und Attribute optional, mit einem entscheidenden Unterschied: Aus dem Schema von OTR lässt sich entnehmen, dass das Element `<e:started>` folgende Attribute aufweisen muss: `id`, `time` und `name` [5]. Während `id` intern in der Ausgabe benötigt wird, um die verschiedenen Events einander zuzuordnen, und `time` lediglich den Zeitpunkt des Beginns des Events festhält, ist für die Eignung von OTR als Input für

`testAuditor` vor allem `name` interessant: Dieses Attribut enthält den Namen des Testcase. Für `<e:finished>` sind lediglich `id` und `time` verpflichtend, jedoch bleibt die Zuordnung zu `name` über `id` erhalten.

Jedoch genügt, wie bereits bei TAP in Codeblock 4.7 gezeigt, das Vorhandensein des bloßen Namens nicht zur eindeutigen Identifizierung eines Testcase. Die dazugehörige Suite wird in OTR innerhalb des Elements `<metadata>` angegeben. Dieses Element ist jedoch optional. Somit ist die eindeutige Zuordnung von Testcases zu ihren Ergebnissen zwar teilweise in der Struktur festgehalten, aber noch nicht ausreichend garantiert.

Eignung

Da OTR zum Zeitpunkt der Niederschrift dieser Bachelorarbeit noch sehr jung ist und aktiv entwickelt wird, bleibt abzuwarten, ob die Entwickler ihr Ziel eines standardisierten, programmiersprachenunabhängigen Testausgabeformates erreichen können.

Außerdem ist die Verbreitung von OTR noch sehr begrenzt: Von den in Tabelle 1 betrachteten Testframeworks sind lediglich PHPUnit und JUnit5 (das, wie eingangs erwähnt, vom selben Entwicklerteam wie OTR betreut wird) mit jupiter als Runner in der Lage, OTR nativ zu erzeugen. Außerdem kann JUnit5 mit den Runnern von Maven/Gradle zumindest über Plugins eine OTR-Ausgabe erzeugen.

Fazit zu OTR

Auch wenn OTR unter den bisher untersuchten Testausgabeformate die geeignetste Struktur bietet, ist die Verbreitung von OTR zum aktuellen Zeitpunkt noch zu gering, um die Framework-Agnostik des Verfahrens gewährleisten zu können, sollte es als Input für `testAuditor` genutzt werden.

4.2.4 Andere Formate

Neben den bisher untersuchten ganz oder teilweise strukturierten Formaten bieten viele Testframeworks auch unstrukturierte Ausgaben in unterschiedlichen Dateiformaten an. Konkret wurden bei der Untersuchung des Datensatzes

Testausgaben in den folgenden Dateiformaten identifiziert:

- XML (ohne JUnit XML oder OTR)
- HTML (ohne OTR)
- JSON

Das Problem bei diesen Testausgaben ist, dass ihre Struktur voll und ganz von dem Testframework abhängig ist, von dem sie erzeugt werden.

JSON, von pytest in Python erzeugt:

```
{"created": 1782247688.1675658,
"duration": 0.024770736694335938,
"exitcode": 1,
"root": "/home/.../python/src",
"environment": {},
"summary": {
  "passed": 3,
  "failed": 1,
  "skipped": 1,
  "total": 5,
  "collected": 5
},
"collectors": [
...

```

JSON, von Behat in PHP erzeugt:

```
{"tests": 5,
"skipped": 0,
"failed": 2,
"pending": 0,
"undefined": 0,
"time": 0.011,
"suites": [
...

```

Codeblock 4.9: Vergleich von der JSON-Ausgabe von pytest und Behat.
"..." bezeichnet gekürzte Stellen.

Für diese von Grund auf verschiedenen Ausgaben kann kein gemeinsames semantisches Datenmodell abgeleitet werden, auf dem ein Parser basieren kann, zumal auch unbekannte Strukturen von anderen Testframeworks berücksichtigt werden müssten.

Somit können für die Wahl des Inputs für `testAuditor` nur die zuvor untersuchten Testausgabeformate in Betracht gezogen werden.

4.3 Fazit zur Evaluation der Testausgabeformate

Tabelle 3 zeigt eine Übersicht darüber, welches der drei relevanten Testausgabeformate (JUnit XML, TAP, OTR) welche Anforderung aus Kapitel 3.2 erfüllen kann:

Anforderung	JUnit XML	TAP	OTR
ermöglicht Ermittlung aller vorhandenen Testcases	✗	✗	✗
eindeutige Identifizierung von Testcases	~	~	~
sagt für jeden Testcase einzeln aus, ob er ausgeführt wurde oder nicht	~	~	~
strukturiertes Format	~	✓	✓
weite Verbreitung	✓	~	~

✓ Erfüllt
 ~ In Teilen erfüllt
 ✗ Nicht erfüllt

Tabelle 3: Evaluation der Testausgabeformate nach den in Kapitel 3.2 definierten Anforderungen

Anhand der vorangegangenen Evaluation der unterschiedlichen Testausgabeformate und Tabelle 3 wird deutlich, dass es keinen eindeutigen Kandidaten für die Wahl als Input für `testAuditor` gibt, der alle in Kapitel 3.2 gelisteten Anforderungen erfüllt.

Allen der untersuchten Testausgabeformate ist gemeinsam, dass keines die Gesamtheit aller Testcases im Projekt angibt, sondern ausschließlich Testcases,

die ausgeführt wurden. Die eindeutige Zuordnung von Testergebnissen zu den Testcases ist in allen drei relevanten Ausgabeformaten nur möglich, wenn die richtigen optionalen Attribute vom jeweiligen Testframework verwendet werden. Da die Gesamtmenge der Testcases nicht bekannt ist, lässt sich nur für die enthaltenen Testcases feststellen, dass sie berücksichtigt wurden, während die Menge der nicht ausgeführten Testcases unbekannt bleibt.

Unterschiede gibt es bei der Strukturierung der Formate: In diesem Aspekt ist OTR das besten geeignete Format, da OTR im Gegensatz zu TAP und JUnit XML das Vorhandensein des Namens eines Testcase im Ausgabeformat garantiert. Eine eindeutige Zuordnung kann dadurch allerdings noch nicht garantiert werden, da zusätzliche Informationen fehlen, konkret die Testsuite oder Klasse, zu der der Testcase gehört.

Der wichtigste Aspekt, um einen Testframework-agnostischen Input für `testAuditor` zu bestimmen, ist die Verbreitung des Testausgabeformats in verschiedenen Testframeworks. Selbst ein Format, das alle anderen Anforderungen komplett erfüllt, wäre in diesem Falle nutzlos, wenn es nicht von einer Vielzahl von Testframeworks unterstützt wird.

Somit fällt die Wahl als Input für `testAuditor` auf JUnit XML.

Trotz aller in Kapitel 4.2.1 gezeigten Schwächen wird JUnit XML von einer Vielzahl von Testframeworks als Ausgabeformat angeboten. Darüber hinaus ist die tatsächliche Implementierung des Formats von JUnit XML trotz einer fehlenden Standardisierung häufig genug an den kritischen Punkten übereinstimmend, sodass ein Parser geschrieben werden kann, der in einer Vielzahl von Fällen funktioniert.

Natürlich wäre es wünschenswert, ein strukturiertes Format zu verwenden, um eine sichere Aussage über den Anwendungsbereich des Verfahrens treffen zu können. Um die Anforderung der Framework-Agnostik so weit wie möglich zu erfüllen, überwiegt hier jedoch das Argument der überragenden Verbreitung von JUnit XML.

5 Konzeptionierung und Umsetzung

5.1 Komponenten des Verfahrens

Das vorgestellte Verfahren besteht aus den folgenden Komponenten:

- **testDiscovery**: Liefert die Gesamtheit aller Testcases
- **test archive**: Enthält die Ausgabe aller Testdurchläufe, die für den aktuellen Stand beachtet werden sollen
- **testAuditor**: Ermittelt, welche Testcases noch ausgeführt werden müssen
- **testExecution**: Führt eine gegebene Menge von Testcases aus
- **controller**: Steuert die Interaktion mit dem **user** sowie die Kommunikation zwischen den Komponenten
- **user**: Interagiert nach eigenem Ermessen mit dem controller

Eine Übersicht über die Interaktion der einzelnen Komponenten liefert Abbildung 1:




Abbildung 1: Schematische Darstellung der Interaktion von **user**, **controller**, **testAuditor**, Hilfskomponenten und dem Testframework.

Im Folgenden werden die einzelnen Komponenten des Verfahrens, sowie ihr Zusammenspiel im Detail erläutert.

5.1.1 testDiscovery

Durch die Wahl von JUnit XML als Ausgabeformat, das von `testAuditor` als Input verwendet wird, müssen die in Kapitel 3.2 aufgelisteten Anforderungen, die von JUnit XML nicht erfüllt werden, anderweitig umgesetzt werden, damit alle in Kapitel 3.1 formulierten Anforderungen erreicht werden können.

Die größte Herausforderung ist, dass aus einer JUnit-XML Ausgabe nur jene Testcases ermittelt werden können, die während des Testlaufs ausgeführt wurden. `testAuditor` benötigt jedoch zwingend Informationen über die Gesamtheit aller Testcases im Projekt.

Diesem Zweck dient die `testDiscovery`:

Bei dieser Komponente bietet sich die Implementierung als Shellskript an, da sie bei einem Aufruf die Gesamtheit aller Testcases des Projektes in einem definierten Format ausgeben soll. Manche Testframeworks bieten Zugriff auf ihre interne Testcases-Discovery, was in diesen Fällen die Implementation mit geringem zusätzlichen Aufwand ermöglicht.

Format der Ausgabe der testDiscovery

`testAuditor` erwartet die Ausgabe der `testDiscovery` in diesem Format:

```
<?xml version="1.0" encoding="utf-8"?>
<testsuite>
  <testcase classname="" name="" qualifiedName=""/>
  <testcase classname="" name="" qualifiedName=""/>
</testsuite>
```

Codeblock 5.1: Format der `testDiscovery`

Die Werte der beiden Attribute `classname` und `name` für einen Testcase müssen dabei zwingend identisch mit den Werten der beiden Attribute sein, wie sie in der JUnit-XML Ausgabe des Testcase stehen, da die Kombination dieser beiden Attribute innerhalb des Verfahrens als Schlüssel zur Identifizierung von Testcases

benutzt werden, wie in Kapitel 4.2.1 ff. erläutert.

`qualifiedName` enthält eine Zeichenfolge, über die das Testframework einen Testcase identifizieren und ausführen kann. Je nach Testframework werden dazu der Name des Testcase, Dateipfade, Namen von Klassen oder Testsuites und/oder weitere Informationen benötigt. `qualifiedName` dient der `testExecution` (siehe Kapitel 5.1.4) als Identifikator von Testcases bei der Ausführung.

Die `testDiscovery` ist hochgradig vom verwendeten Testframework abhängig, da die frameworkspezifische Implementierung der Testausführung des jeweiligen Testframeworks beachtet werden muss. Daher muss diese Komponente für jedes Softwareprojekt eigens angepasst werden.

5.1.2 test archive

Das `test archive`, kurz `archive`, beschreibt die Komponente des Verfahrens, welche die in JUnit XML festgehaltenen Testausgaben von vorherigen Testläufen beinhaltet, die `testAuditor` als Input zur Verfügung gestellt werden sollen.

Ein Projekt muss so konfiguriert werden, dass sichergestellt ist, dass keine Dateien aus dem `archive`, die sich auf einen alten Stand des Projekts beziehen, vom Verfahren genutzt werden. Hierfür bietet sich die Implementierung des `archive` über `Git Notes` an, wie im folgenden Abschnitt erläutert wird.

Git Notes

Eine wenig bekannte Funktionalität von `Git` ist, dass an einen Commit sogenannte `Git Notes` angehängt werden können. Der Inhalt dieser `notes` wird separat vom eigentlichen Inhalt des Commits verwaltet; der Hash eines Commits wird nicht durch Änderungen an den `notes` beeinflusst. Dadurch können einem Commit zusätzliche Informationen hinzugefügt werden, ohne die Historie des Repositories zu verändern.

Aus diesen Gründen bieten sich `git notes` in zweierlei Hinsicht für die Rolle des `test archive` an:

Zum einen wird das eigentliche Projekt nicht durch zusätzliche Dateien vom Verfahren verändert. Zum anderen gehört jede `note` zu genau einem Commit, wodurch vermieden werden kann, dass das Verfahren Dateien aus dem `archive`

für einen vorherigen Commit erhält, da die **notes** für jeden Commit neu erstellt werden müssen.

5.1.3 testAuditor

Die Funktionalität von **testAuditor** als Kern des Verfahrens lässt sich am besten mit einfachen Mengenoperationen beschreiben:

Sei T_{ges} die Menge aller Testcases eines Projektes und T_{known} die Menge aller Testcases, für die ein Ergebnis vorliegt. **testAuditor** berechnet $T_{ges} - T_{known} = T_{todo}$, wobei T_{todo} die Menge aller Testcases ist, für die noch kein Ergebnis vorliegt. Da nach Kapitel 1.3 von der Korrektheit von T_{known} ausgegangen werden darf, gilt $T_{known} \subseteq T_{ges}$. Weiterhin gilt $T_{todo} \subseteq T_{ges}$.

Da $T_{known} \cup T_{todo} = T_{ges}$, kann die vollständige Abdeckung aller Testcases garantiert werden, sofern eine fehlerlose Implementierung der Komponenten vorliegt. T_{ges} wird von **testDiscovery** bereitgestellt, während das **test archive** T_{known} enthält. Beide Datenmengen werden **testAuditor** vom **controller** in dem in Kapitel 5.1.3 definiertes Format übermittelt.

Abschließend gibt **testAuditor** eine Menge von **qualifiedNames** an den **controller** zurück. Diese Menge beschreibt T_{todo} , und wird von **testAuditor** auf **stdout** gelegt.

Format zur Kommunikation mit testAuditor

Das Verfahren nutzt einen Wrapper, der die Ausgabe von **testDiscovery** und die Dateien aus dem **archive** kapselt, um den Input für **testAuditor** bereitzustellen.

```
<?xml version="1.0" encoding="utf-8"?>
<testAuditorInput version="1.0">
  <testDiscovery>
    <![CDATA[...]]>
  </testDiscovery>
  <reports>
    <report format="junit-xml">
      <![CDATA[...]]>
    </report>
  </reports>
</testAuditorInput>
```

```
</testAuditorInput>
```

Codeblock 5.2: Kommunikationsformat für `testAuditor`

Dieses Format muss vom `controller` bereitgestellt werden. `testAuditor` erwartet den Input auf `stdin`.

Parser für JUnit XML

Das Parsen des vorangehend beschriebenen Kommunikationsformats sowie des in Kapitel 5.1.1 beschriebenen Formats der `testDiscovery` ist trivial.

Interessanter ist die Umsetzung eines Parsers für die im `archive` gespeicherten JUnit-XML Dateien. Wie in Kapitel 4.2.1 behandelt, besitzt JUnit XML kein standardisiertes Schema. Dementsprechend muss ein Parser für solche Dateien auf eine Art und Weise konfiguriert werden, die ohne eine verbindlich festgelegte Struktur auskommt. Dafür wird bei der Implementation des Parsers ein streamingbasierter Ansatz verwendet:

Die XML-Datei wird sequenziell Element für Element eingelesen. Sobald ein Element mit dem Namen `<testcase>` gefunden wird, wird überprüft, ob dieses Element die Attribute `name` und `classname` enthält. Ist dies der Fall, so wird das Element zur Menge an bereits durchgeführten Testcases hinzugefügt.

Durch diese Art der Implementierung können zwar auch Testausgaben in JUnit XML syntaktisch verarbeitet werden, welche die Attribute `name` und/oder `classname` nicht benutzen (siehe Codeblock 4.4), jedoch wird durch das Fehlen von Attributen jeder Testcase als nicht ausgeführt betrachtet, was die Anwendung des Verfahrens hinfällig macht, da kein Testcase als durchgeführt betrachtet wird und in jedem Durchlauf des Verfahrens jeder Testcase ausgeführt wird.

Die konkrete Implementierung des Parser ist im unter Kapitel 8 verlinkten Repository für `testAuditor` dokumentiert.

5.1.4 `testExecution`

Die Komponente `testExecution` ist die Schnittstelle des Verfahrens zum Testframework. Sie ist eng mit der Komponente `testDiscovery` gekoppelt, denn

die `testExecution` erwartet eine Menge von `qualifiedName`, die sie zur gezielten Ausführung an das Testframework übergibt. Die genaue Struktur der `qualifiedNames` wird in Kapitel 5.1.1 beschrieben, und wie in Kapitel 5.1.1 von der `testDiscovery` im Verfahren etabliert.

Die Menge von `qualifiedName`, welche von der `testExecution` an das Testframework übermittelt werden soll, wird wie vorhergehen in Kapitel 5.1.3 beschrieben von `testAuditor` ermittelt.

Ebenso wie die `testDiscovery` ist die genaue Implementierung der `testExecution` hochgradig vom verwendeten Testframework abhängig, da sie direkt mit dem jeweiligen Testframework kommuniziert.

5.1.5 controller

Als `controller` wird jene zentrale Komponente beschrieben, die als einzige Komponente direkt mit dem `user` interagiert, und die Ausführung der einzelnen Komponenten des Verfahrens koordiniert, sowie I/O-Prozesse der Komponenten und die Fehlerbehandlung verwaltet.

Typischerweise erfüllt eine CI-Pipeline die Rolle des `controllers` innerhalb eines Projekts, allerdings kann der `controller` auch auf andere Weise implementiert werden.

5.1.6 user

Die Bezeichnung `user` ist bewusst breit interpretierbar gehalten. Sie beschreibt eine externe Instanz, die mit dem `controller` interagiert, dadurch den Ablauf des Verfahrens anstößt und/oder die Ausgabe des Verfahrens konsumiert. Dabei kann es sich beim `user` um einen menschlichen Benutzer oder einen automatisierten Prozess handeln.

5.2 Anforderungen an ein Testframework

Das beschriebene Verfahren kann mit jedem Testframework angewendet werden, welches diese Voraussetzungen erfüllt, die sich unter anderem aus Kapitel 4.3 ergeben:

- Eine beliebig kleine Untermenge aller Testcases kann gezielt ausgeführt werden
- JUnit XML wird als Ausgabeformat für Testläufe verwendet
- Ein Testcase kann eindeutig über die Kombination der Attribute **name** und **classname** identifiziert werden

5.3 Anforderungen an ein Projekt

Nachdem die Anforderungen und Funktionsweisen der beteiligten Komponenten und Dateien ausführlich diskutiert wurden, können daraus nun die Anforderungen an ein Projekt abgeleitet werden, die vorausgesetzt werden, um das Verfahren in ein Projekt integrieren zu können:

- Reproduzierbarkeit ist wie nach Kapitel 3.3 gegeben: Jeder Testdurchlauf erzeugt bei gleichem Input und gleicher Konfiguration der Testcases dasselbe Ergebnis, unabhängig von der verwendeten Umgebung
- Das verwendete Testframework erfüllt alle in Kapitel 5.2 dargestellten Anforderungen
- Es werden Komponenten zur Verfügung gestellt, welche die in Kapitel 5.1 beschriebenen Funktionalitäten bereitstellen

6 Analyse der Laufzeit

In diesem Kapitel werden die Ergebnisse der begleitenden Benchmark (siehe Kapitel 8) präsentiert und erörtert.

6.1 Aufbau der Benchmark

Die hier benutzte Benchmark ist in Python für das Framework `pytest` geschrieben und untersucht sechs verschiedene Basiskonfigurationen. Diese Konfigurationen unterscheiden sich in der Gesamtzahl der Testcases, die ausgeführt werden, sowie in der Anzahl der Iterationen, die je Testcase ausgeführt werden, was die Ausführungsdauer eines Testcase bestimmt. Jede Konfiguration wird mit sechs verschieden gefüllten `archives` getestet.

Dabei werden die sogenannten parametrisierten Tests von `pytest` genutzt, wie in Codeblock 6.1 dargestellt:

```
@pytest.mark.parametrize("case", range(10))
def test_simple(case):
    index = 0
    for i in range(100):
        index += 1
    assert index == 100
```

Codeblock 6.1: Inhalt von `test_simple.py` aus der Konfiguration `"bench_fast_few_00"`

`range(x)` in der obersten Zeile bestimmt, wie viele Instanzen des Testcase mit durchnummerierten Namen beim Ausführen des Testcase erstellt werden.

`range(y)` in der `for`-Schleife in der vierten Zeile bestimmt die Anzahl der Iterationen, die im Testcase ausgeführt werden, bevor er abgeschlossen wird.

Das in Codeblock 6.1 demonstrierte Beispiel erzeugt also 10 Testcases, die jeweils 100 Iterationen ausführen. Die Konfigurationen werden in 3 Geschwindigkeitsklassen unterteilt: *fast*, *medium* und *slow*. Für jede dieser Geschwindigkeitsklassen existieren zwei Untergruppen: *few* bezeichnet eine Konfiguration mit wenigen Testcases, *many* eine mit vielen. Dabei wird die Gesamtzahl der Iterationen zur Wahrung einer gewissen Vergleichbarkeit innerhalb einer Geschwindigkeitsklasse

gleich gehalten. Ein Beispiel: Während die Konfiguration **fast_few** 10 Testcases mit je 100 Iterationen enthält, enthält die Konfiguration **fast_many** 100 Testcases mit je 10 Iterationen. Somit werden in beiden Konfigurationen $10 \times 100 = 1000$ Iterationen ausgeführt, jedoch in unterschiedlichen Strukturen.

Jede Konfiguration enthält außerdem die Datei `out.xml` im Ordner `archive`. Diese Datei enthält das Ergebnis von vorherigen Testläufen, die vom Verfahren genutzt werden können, und erfüllt damit die Rolle des **archive**, wie in Kapitel 5.1.2 definiert ist. Dabei existieren für jede der sechs bisher vorgestellte Kombination aus Testcaseanzahl und Iterationsanzahl sechs Konfigurationen: Eine Konfiguration enthält ein leeres **archive**; darauf folgen Konfigurationen, in denen das **archive** jeweils 20, 40, 60, 80 und abschließend 100 Prozent der Testcases in der Konfiguration abdeckt.

Durch die drei Geschwindigkeitsklassen, die beiden unterschiedlichen Mengen von Testcases, und den unterschiedlich gefüllten **archives** beträgt die Gesamtzahl der in der Benchmark untersuchten Konfigurationen 36.

Die Komponenten **testDiscovery** und **testExecution** werden durch zwei gleichnamige Skripte zur Verfügung gestellt. Das Skript `benchmark.sh`, das den Ablauf der Benchmark steuert, übernimmt die Rolle des **controller**.

6.1.1 Spezifikationen des ausführenden Systems

Der Computer, auf dem die Benchmark ausgeführt wurde, weist folgende Hardware-Spezifikationen auf:

- Prozessor: AMD Ryzen 5 7600, 3801 MHz, 6 Kerne, 12 logische Prozessoren
- RAM: 32,0 GB DDR5-6000
- Massenspeicher: 1TB NVMe SSD

Die Benchmark wurde unter **Windows Subsystem for Linux (WSL)** ausgeführt. Nähere Informationen zur Softwareumgebung können der Datei `flake.lock` im Repository der Benchmark (siehe Kapitel 8) entnommen werden.

6.2 Datenerhebung der Benchmark

Es gilt zu beachten, dass die Benchmark die Dauer des gesamten Prozesses der Testausführung misst. Für das in dieser Bachelorarbeit vorgestellte Verfahren bedeutet dies, dass die Ausführung der `testDiscovery`, die Ausführung von `testAuditor` sowie der Ablauf der `testExecution` gemessen werden. Die Steuerung der Komponenten durch den `controller` sorgt dabei für einen zusätzlichen testframeworkabhängigen Overhead.

Um einen direkten Vergleich der Ergebnisse zu ermöglichen, werden für jeden Durchlauf einer Konfiguration zwei individuelle Durchläufe gestartet:

Der erste Lauf besteht aus der konventionellen Ausführung von Tests, bei der alle vorhandenen Testcases neu ausgeführt werden. Der zweite Lauf verwendet das in dieser Bachelorarbeit entwickelte Verfahren, um auf Grundlage der im `archive` gespeicherten Testausgaben die erneute Ausführung von Testcases zu vermeiden.

Um die Auswirkungen von systembedingten äußeren Einflüssen beim Ablauf der Benchmark auf die ermittelten Laufzeiten zu verringern, wird die gesamte Benchmark zehnmal vollständig wiederholt. Das arithmetische Mittel ist dann die Grundlage für die Auswertung in Kapitel 6.3.

6.3 Ergebnisse der Benchmark

T bezeichnet die Anzahl der Testcases in der Konfiguration.

I bezeichnet die Anzahl der Iterationen pro Testcase.







Abbildung 2: Ergebnisse der Benchmark. Sämtliche dieser Übersicht zugrunde liegenden Daten können in dem Repository der Benchmark (siehe Kapitel 8) eingesehen und überprüft werden.




(a) wenige kurze Testcases: $T=10, I=100$




(b) viele kurze Testcases: $T=100, I=10$




(c) wenige mittellange Testcases: $T=10, I=1.000.000$



(d) viele mittellange Testcases: $T=1.000, I=10.000$



(e) wenige langsame Testcases: $T=10, I=10.000.000$



(f) viele langsame Testcases: $T=10.000, I=10.000$

Abbildung 3: Detailansicht zu den Laufzeiten einzelner Komponenten des Verfahrens. Sämtliche dieser Übersicht zugrunde liegenden Daten können in dem Repository der Benchmark (siehe Kapitel 8) eingesehen und überprüft werden.

6.4 Zusammenfassung der Ergebnisse

Aus Abbildung 2 ist ersichtlich, dass sich mit der Anwendung des Verfahrens durchaus eine Verringerung der Laufzeit eines Testdurchlaufs erreichen lässt. Durch die Verwendung der verschiedenen Komponenten des Verfahrens und der notwendigen Kommunikation dieser untereinander entsteht zwar ein gewisser Overhead im Vergleich zu einem konventionellen Testdurchlauf, dieser nimmt jedoch mit zunehmender Abdeckung von Testcases in **archive** nahezu konstant ab.

Jedoch zeigen die Graphen (2), (4) und (6) einen Mangel auf: Bei einer hohen Anzahl von Testcases, die ausgeführt werden müssen, ist die Laufzeit des Verfahrens zum Teil deutlich höher als ein konventioneller Durchlauf. Abbildung 3 liefert die Erklärung zu diesem Verhalten: Während die Laufzeiten für die **testDiscovery**, den **testAuditor** und den sonstigen Overhead, der durch das ausführende Skript entsteht, innerhalb einer Konfiguration der Benchmark nahezu konstant bleiben, ist die Laufzeit der **testExecution** stark von der vorhandenen Menge an Testcases abhängig. Vergleicht man einzelne Graphen derselben Konfiguration aus Abbildung 2 und Abbildung 3 miteinander, so ist ersichtlich, dass die **testExecution** bei gleicher Anzahl an Testcases deutlich langsamer ist, als ein konventioneller Testlauf. Dies lässt sich durch das verwendete Testframework und die Funktionsweise der **testExecution** erklären:

Die **testExecution** bekommt von **testAuditor** eine Menge an Namen von Testcases, die ausgeführt werden sollen. In dieser Benchmark wird diese Menge von der **testExecution** an **pytest** übergeben, was bei einer hohen Anzahl von Testcases eine sehr laufzeitintensive Operation werden kann. Außerdem ist **pytest** nicht effizient auf diese Art der Verwendung ausgelegt, sodass die Laufzeit bei dieser Art von Aufruf mit vielen Testcases deutlich länger als bei einem konventionellen, vollständigen Testlauf ist. Der Grad der Auswirkung dieser Implementationsweise ist also auch abhängig vom verwendeten Testframework. Es ist zu erwarten, dass sich die Performance des Verfahrens von Testframework zu Testframework unterscheidet.

Die beste Performance zeigt das Verfahren jedoch in Fällen wie in Graph (5)

demonstriert:

Bei einer geringen Anzahl von Testcases fällt die langsame Implementation der `testExecution` weniger ins Gewicht, und bei einer langen Laufzeit der einzelnen Testcases kann durch das Vermeiden des erneuten Ausführens von Testcases eine deutliche Verringerung der Gesamtlaufzeit des Testdurchlaufs erzielt werden. So weist das Verfahren in (5) ab einer Abdeckung der Testcases von etwa 20% bereits eine kürzere Laufzeit als der konventionelle Durchlauf auf.

Je mehr Testcases bereits ausgeführt wurden, desto kürzere Laufzeiten erzielt das Verfahren. Selbst bei Konfigurationen mit vielen Testcases ist das Verfahren ab einer Abdeckung von etwa 80% der Testcases durch `archive` schneller als ein konventioneller Durchlauf. Ausnahmen bilden Konfigurationen mit Testcases mit sehr kurzer Laufzeit: Hier ist der Laufzeitgewinn pro gespartem Testcase gering, und der Overhead des Verfahrens überwiegt die eingesparte Laufzeit, sodass die Laufzeit eines konventionellen Durchlaufs kürzer als mit dem Verfahren ist, wie in (1) und (2) ersichtlich.

7 Fazit

7.1 Erfüllung der Anforderungen

In diesem Kapitel folgt die Beurteilung, ob die in Kapitel 3.1 gestellten Anforderungen unter Berücksichtigung der Ergebnisse von Kapitel 6.3 durch das Verfahren erfüllt werden konnten.

- **Die Wahl der verwendeten Testframework(s) ist unerheblich**

Das Verfahren ist frameworkunabhängig für jedes Testframework, welches die in Kapitel 5.3 gestellten Anforderungen erfüllt, also für jedes Framework, welches JUnit XML als Ausgabeformat bereitstellt, und eine eindeutige Zuordnung zwischen Testausgabe und Testcase über die Attribute `name` und `classname` ermöglicht.

- **Nach Abschluss des Verfahrens wurde jeder Testcase für den aktuellen Stand des Codes mindestens einmal durchgeführt**

Die Implementation von `testAuditor` in Kapitel 5.1.3 garantiert eine korrekte Ermittlung der fehlenden Testergebnisse, da nach Kapitel 1.3 die Korrektheit des Inputs angenommen wird.

- **Die Ausgabe des durch das Verfahren ausgeführten Testlaufs ist auf dieselbe Weise verfügbar, wie die anderen Ausgaben**

Diese Anforderung kann von einem korrekt implementierten `controller` erfüllt werden, da die `testExecution` auf dasselbe Testframework wie die vorherigen Testläufe zugreift, und ihr Ergebnis an den `controller` zurückmeldet. Die genau Vorgehensweise ist zwar von der jeweiligen Implementation des `archive` und `controllers` anhängig, die notwendigen Voraussetzungen zur Erfüllung dieser Anforderung sind jedoch durch das Verfahren erfüllt.

- **Die Laufzeit eines Testdurchlaufs unter Verwendung des Verfahrens ist kleiner oder gleich der Laufzeit eines konventionellen Durchlaufs**

Diese Anforderung konnte mit Blick auf Kapitel 6.4 nur teilweise erfüllt werden, da die Laufzeit für einen Durchlauf ohne Inhalte im `archive` langsamer als ein konventioneller Durchlauf ist. Jedoch wird die Laufzeit des Verfahrens kürzer, je mehr Testcases bereits ausgeführt wurden und deren Ergebnis im `archive` liegt. Der Punkt, ab dem das Verfahren schneller abläuft, als ein konventioneller Durchlauf, ist abhängig von Anzahl und Ausführungsgeschwindigkeit der Testcases.

7.2 Schlussbetrachtung

Zusammenfassend lässt sich sagen, dass durch das in dieser Bachelorarbeit entwickelte Verfahren durchaus eine Verkürzung der Laufzeit von Testläufen erzielen lässt. Es wurde erklärt, von welchen Faktoren der genau Wert der Verkürzung in einem Projekt abhängig ist.

Außerdem wurden die Schwierigkeiten beim Versuch, eine möglichst umfassende Unabhängigkeit vom benutzten Testframework zu erzielen, dargestellt. Es wurde die breite Verwendbarkeit des Verfahrens in verschiedenen Testframeworks, aber auch die Limitationen dieser Unabhängigkeit genau durchleuchtet.

Die zu Beginn gestellte Frage:

(Wie) Kann die Laufzeit von Testläufen unabhängig vom verwendeten Testframework durch die Wiederverwendung bereits vorhandener Testergebnisse reduziert werden, ohne die Aussagekraft der Testergebnisse zu beeinträchtigen?

kann also mit *”Ja, unter gewissen Voraussetzungen.”* beantwortet werden. Die Klärung des *”Wie”* ist Inhalt von Kapitel 4 und Kapitel 5.

7.3 Möglichkeiten zur Verbesserung

In seiner aktuellen Form kann das Verfahren nicht überprüfen, ob die bereitgestellten XML-Ausgaben der Tests auch tatsächlich aus dem aktuellen Stand des Codes entstammen, oder ob im Nachhinein Änderungen an dem zu testenden Code oder den Tests selber vorgenommen wurden. Die Verwendung veralteter

Ergebnisse kann die Aussagekraft des Verfahrens erheblich beeinträchtigen. Eine mögliche Lösung wäre, jedes Testergebnisses eindeutig zu einem Commit zuzuordnen. So könnte zumindest überprüft werden, ob das Ergebnis aus dem aktuellen Commit entstammt.

Ein anderes Problem ist, dass das Tool alle Tests, deren Ergebnis nicht im **archive** vorhanden ist, als nicht abgelaufen. Allerdings ist es möglich, dass Testcases in einer vorherigen Iteration ausgeführt wurden, und seither sich weder die Testcases noch der betroffene Code geändert hat. In diesem Fall kann das Ergebnis dieser Testcases weiterhin als valide betrachtet werden, und diese Testcases müssen nicht erneut ausgeführt werden.

Eine Möglichkeit, hier nachzubessern, wäre die Integration eines neuen Tools, welches das hier entwickelte Verfahren mit einer Regression Test Selection wie in Kapitel 2.2 verbindet. So kann die Menge der Testcases, die abgelaufen werden müssen, weiter beschränkt werden, was eine zusätzliche Verringerung der Laufzeit verspricht.

Eine weitere Möglichkeit, das Verfahren zu verbessern, besteht in der Implementation von zusätzlichen Parsern in **testAuditor** für andere Formate als JUnit XML, wie beispielsweise TAP oder OTR. Dies würde die Integration der Verfahrens in Projekte ermöglichen, die eines dieser weiteren Formate, aber kein JUnit XML nutzen.

Zusätzlich könnte untersucht werden, ob eine effizientere Methode der Kommunikation mit dem Testframework als mit dem aktuellen Aufbau möglich ist, um das Verfahren bei bereits geringerer Abdeckung des **archive** effizienter als einen konventionellen Durchlauf zu machen.

Literaturverzeichnis

- [1] Mauro Pezzè und Michal Young. *Software Testing and Analysis: Process, Principles, and Techniques*. John Wiley & Sons, 2008. ISBN: 978-0-471-45593-6.
- [2] Dietmar Winkler, Reinhard Hametner und Stefan Biffl. “Automation Component Aspects for Efficient Unit Testing”. In: *2009 IEEE Conference on Emerging Technologies & Factory Automation*. IEEE, 2009. DOI: 10.1109/ETFA.2009.5347022.
- [3] Isaac Z. Schlueter. *TAP14 - The Test Anything Protocol v14*. Archivierte Version vom 10.07.2026, verfügbar über die Wayback Machine: <https://web.archive.org/web/20260710220327/https://testanything.org/tap-version-14-specification.html>. 2022. URL: <https://testanything.org/tap-version-14-specification.html> (besucht am 10.07.2026).
- [4] Marc Philipp. *STF Milestone 2: Open Test Reporting*. Archivierte Version vom 11.07.2026: <https://web.archive.org/web/20260710233305/https://marcphilipp.de/blog/2025/03/21/stf-milestone-2-open-test-reporting/>. 21. März 2025. URL: <https://marcphilipp.de/blog/2025/03/21/stf-milestone-2-open-test-reporting/> (besucht am 11.07.2026).
- [5] ota4j-team. *Open Test Reporting*. Archivierte Version vom 11.07.2026: <https://web.archive.org/web/20260711211234/https://github.com/ota4j-team/open-test-reporting/blob/main/README.adoc#xml-formats>. URL: <https://github.com/ota4j-team/open-test-reporting/blob/main/README.adoc#xml-formats> (besucht am 11.07.2026).

8 Links

L^AT_EX-Code der vorliegenden Bachelorarbeit:

https://github.com/Zip-creations/BA_latex

Evaluation der Testausgabeformate ausgewählter Testframeworks:

https://github.com/Zip-creations/evaluate_testformats

Quellcode von testAuditor:

<https://github.com/Zip-creations/testAuditor>

**Exemplarischer Aufbau des Verfahrens in einem Python-Projekt mit
pytest:**

https://github.com/Zip-creations/BA_showcase

Benchmark mit allen .log-Dateien:

https://github.com/Zip-creations/BA_benchmark